

TECNUN — UNIVERSIDAD DE NAVARRA
Escuela de Ingeniería

Proyecto Fin de Máster

ANÁLISIS DE DATOS EN INGENIERÍA

Aprendizaje federado para la previsión de demanda en retail: evaluación frente a modelos locales, centralizados y convencionales

Alessandro Flammia
Donostia-San Sebastián, septiembre de 2026

Resumen

Pendiente de redacción.

Abstract

Pending.

Agradecimientos

A Idoia Ochoa, por dirigir este trabajo y por reorientarlo cuando hacía falta. La decisión de no quedarse en la comparación técnica y exigirle al proyecto una justificación de negocio cambió el alcance de la memoria para bien.

A mi familia, por el apoyo durante todo el máster.

A Tecnun y a sus profesores, por la formación que hay detrás de este trabajo.

Índice general

Resumen	i
Abstract	ii
Agradecimientos	iii
1. Introducción	1
1.1. Contexto	1
1.2. El aprendizaje federado como alternativa	2
1.3. Motivación y enfoque	2
1.4. Aportaciones	3
1.5. Estructura del documento	4
2. Estado del arte	5
2.1. Previsión de demanda en distribución	5
2.2. Aprendizaje federado	6
2.2.1. Formulación básica	6
2.2.2. Heterogeneidad entre participantes	6
2.2.3. Aplicación a la previsión en distribución	7
2.3. Colaboración con protección de datos	7
2.3.1. El aprendizaje federado como tecnología de protección de la privacidad	7
2.3.2. Data clean rooms	8
3. Objetivos y preguntas de investigación	9

3.1. Objetivo general	9
3.2. Preguntas de investigación	9
3.3. Objetivos específicos	10
3.4. Alcance y delimitación	10
4. Materiales y métodos	12
4.1. Conjunto de datos	12
4.1.1. Granularidad de la previsión	12
4.1.2. Definición de los silos	13
4.2. Preparación de los datos	13
4.2.1. Agregación y variables exógenas	13
4.2.2. Un problema encontrado en los datos: los huecos de Navidad . .	14
4.2.3. Variables predictoras	14
4.2.4. Partición temporal	15
4.2.5. Ceros estructurales por falta de surtido	15
4.3. Modelo de previsión	16
4.4. Diseño experimental	17
4.5. Métricas y contraste estadístico	18
4.6. Infraestructura	18
5. Resultados	20
6. Discusión	21
7. Análisis de negocio	22
8. Presupuesto	23
9. Conclusiones y líneas futuras	24
Bibliografía	25
A. Anexos	26

Índice de figuras

1.1. El obstáculo a la centralización de datos entre operadores	2
4.1. Composición de los silos	13
4.2. Partición temporal <i>walk-forward</i>	15
4.3. Arquitectura del modelo	16
4.4. Esquema de una ronda de entrenamiento federado	17

Índice de tablas

Capítulo 1

Introducción

1.1. Contexto

La previsión de demanda es una de las decisiones con más consecuencias operativas en la distribución alimentaria. De ella dependen los pedidos a proveedor, la asignación de espacio en lineal y la planificación de personal, y sus errores se materializan en dos costes de signo opuesto: si la previsión se queda corta se produce una rotura de stock, con pérdida de venta y de margen; si se pasa, el excedente acaba en merma, especialmente en las categorías perecederas. En el comercio de alimentación europeo se estima que entre el 5 % y el 7 % de los productos perecederos se desecha, y los perecederos representan aproximadamente la mitad de la venta de un supermercado. Con márgenes netos del sector en torno al 2 %, una mejora moderada de la precisión de la previsión tiene un efecto apreciable sobre el resultado.

La calidad de un modelo de previsión depende en buena medida del volumen y la variedad de datos con los que se entrena. Una tienda aislada dispone de un histórico limitado; un modelo entrenado con los datos de muchas tiendas puede aprender patrones —estacionalidad, efecto de las promociones, comportamiento de los festivos— que en una serie individual quedan ocultos por el ruido. Esta observación empuja de forma natural hacia la centralización de datos.

El problema es que esa centralización no siempre es posible. Dentro de una misma cadena, juntar los datos de sus tiendas es una decisión interna sin obstáculos. Entre operadores distintos, en cambio, los datos de venta a nivel de tienda y producto son información comercial sensible: revelan la estructura de surtido, la posición competitiva y la respuesta a las promociones. A la reticencia competitiva se suma el marco normativo europeo, que impone principios de minimización y limitación de la finalidad sobre los

datos personales que puedan estar implicados. El resultado es una situación paradójica: los operadores que más se beneficiarían de un modelo conjunto son precisamente los que no pueden construirlo por la vía habitual.




Figura 1.1: La vía habitual para mejorar un modelo de previsión —juntar los datos de todos los participantes en un repositorio común— no está disponible cuando los participantes compiten entre sí: los datos de venta por tienda y producto son información comercial sensible.

1.2. El aprendizaje federado como alternativa

El aprendizaje federado propone invertir el flujo habitual: en lugar de mover los datos hacia el modelo, mueve el modelo hacia los datos. Cada participante entrena localmente con su propia información y envía a un coordinador únicamente los parámetros resultantes; el coordinador los promedia y devuelve un modelo agregado que incorpora lo aprendido por todos sin que ninguno haya cedido un solo registro. La formulación de referencia de este esquema es el algoritmo *Federated Averaging* (McMahan et al., 2017).

Sobre el papel, esto encaja con el problema descrito: permitiría a varios operadores construir un modelo conjunto de previsión conservando sus datos. La pregunta que este trabajo se plantea es si ese encaje conceptual se sostiene empíricamente, es decir, si un modelo federado predice mejor que el que cada operador podría entrenar por su cuenta, y cómo se sitúa frente a las alternativas realmente disponibles en la práctica, incluidos los métodos convencionales de previsión que se utilizan a diario en el sector.

1.3. Motivación y enfoque

Buena parte de la literatura de aprendizaje federado evalúa el método frente al escenario centralizado ideal, dando por supuesto que este último constituye el techo de rendimiento alcanzable. Ese marco deja fuera dos comprobaciones que resultan decisivas para justificar su adopción en un caso real. La primera es la comparación con métodos convencionales sencillos: si una media móvil de cuatro semanas iguala el rendimiento de

una arquitectura federada, la complejidad adicional es difícil de defender. La segunda es la cuantificación del beneficio económico, sin la cual no hay criterio para decidir si compensa montar la infraestructura.

Este trabajo adopta por tanto un enfoque doble, técnico y de negocio. En el plano técnico compara cinco condiciones experimentales —local, centralizado por silo, centralizado global, federado y federado con personalización— entre sí y frente a cuatro métodos convencionales de previsión, sobre un mismo conjunto de datos, una misma partición temporal y un mismo protocolo de evaluación, con contraste estadístico de todas las diferencias. En el plano de negocio traduce la mejora obtenida a unidades de error evitadas y, a partir de ahí, a un rango de ahorro económico, y compara el aprendizaje federado con la alternativa comercial más extendida para la colaboración entre empresas que no comparten datos, los *data clean rooms*.

1.4. Aportaciones

Las aportaciones principales de este trabajo son cuatro.

En primer lugar, una comparación homogénea y estadísticamente contrastada de trece métodos de previsión sobre el mismo problema, que sitúa al aprendizaje federado en un marco realista en vez de compararlo únicamente contra el escenario centralizado.

En segundo lugar, la identificación y documentación de tres resultados que contradicen la intuición de partida del proyecto: que centralizar datos de tiendas heterogéneas empeora el modelo en lugar de mejorarlo; que el aprendizaje federado por sí solo rinde peor que el modelo local, siendo la personalización posterior la que lo vuelve competitivo; y que un ajuste de hiperparámetros que beneficia claramente a una etapa del proceso puede perjudicar a la siguiente.

En tercer lugar, un despliegue real del sistema federado sobre tres máquinas independientes en la nube, con aislamiento efectivo de los datos de cada silo, que traslada el experimento desde el entorno de simulación a una infraestructura distribuida.

Por último, un modelo de cuantificación económica que separa de forma explícita lo que se deriva de los datos propios de lo que depende de supuestos externos, y que incorpora un análisis de robustez sobre la distribución del beneficio.

1.5. Estructura del documento

El capítulo 2 revisa el estado del arte en previsión de demanda en distribución, aprendizaje federado y tecnologías de colaboración con protección de datos. El capítulo 3 formula los objetivos y las preguntas de investigación. El capítulo 4 describe los datos, su preparación, el modelo empleado, el diseño experimental y la infraestructura. El capítulo 5 presenta los resultados, incluido el contraste estadístico y el despliegue distribuido. El capítulo 6 los interpreta y expone las limitaciones del estudio. El capítulo 7 aborda las dos preguntas de negocio: la cuantificación del valor y la comparación con los *data clean rooms*. El capítulo 8 recoge el presupuesto del proyecto y el capítulo 9, las conclusiones y las líneas de trabajo futuro.

Capítulo 2

Estado del arte

Este capítulo revisa los tres cuerpos de literatura sobre los que se apoya el trabajo: los métodos de previsión de demanda empleados en distribución, el aprendizaje federado y sus variantes para datos heterogéneos, y las tecnologías de colaboración entre organizaciones que no comparten datos, donde se sitúan tanto el propio aprendizaje federado como los *data clean rooms*.

2.1. Previsión de demanda en distribución

La previsión de ventas en distribución tiene características que la separan de otros problemas de series temporales. El número de series es muy elevado —el producto de tiendas por categorías o referencias—, muchas de ellas son cortas, intermitentes o con ceros estructurales, y las señales relevantes son en buena medida exógenas: promociones, festividades, calendario de cobro y estacionalidad anual.

Los métodos clásicos siguen siendo la referencia de partida. Los modelos ingenuos —la persistencia, que repite el último valor observado, y el estacional, que repite el valor de la misma semana del año anterior— proporcionan el suelo de comparación mínimo. El suavizado exponencial en su formulación de espacio de estados, habitualmente designado como ETS, y los modelos de la familia Holt-Winters añaden tendencia y estacionalidad de forma explícita, y durante décadas han constituido el estándar operativo del sector.

La irrupción de los métodos de aprendizaje automático, y en particular de los árboles potenciados por gradiente, ha desplazado parcialmente ese estándar en las competiciones de previsión. Sin embargo, la evidencia más reciente matiza el entusiasmo: Petropoulos et al. (2024) muestran que en previsión minorista los métodos sencillos y de bajo coste computacional resultan sorprendentemente competitivos frente a alternativas mucho

más complejas, y advierten de que la ganancia marginal de la sofisticación es menor de lo que se suele suponer. Esta observación es directamente pertinente para este trabajo, y motiva la decisión de incluir baselines convencionales en la comparación en lugar de contrastar el modelo federado únicamente contra otras variantes de red neuronal.

2.2. Aprendizaje federado

2.2.1. Formulación básica

El aprendizaje federado fue formulado por McMahan et al. (2017) para entrenar modelos sobre datos distribuidos en dispositivos sin centralizarlos. El algoritmo de referencia, *Federated Averaging* (FedAvg), procede por rondas: el servidor envía los parámetros del modelo global a los participantes; cada uno entrena unas pocas épocas con sus datos locales; el servidor recibe los parámetros resultantes y los promedia ponderando por el número de muestras de cada participante. El proceso se repite hasta convergencia. El dato crudo no abandona en ningún momento al participante.

La literatura distingue dos escenarios según la naturaleza de los participantes. En el federado *cross-device* los participantes son muchos dispositivos con pocos datos cada uno y disponibilidad intermitente. En el federado *cross-silo*, que es el que corresponde a este trabajo, los participantes son pocas organizaciones con volúmenes grandes de datos y disponibilidad estable.

2.2.2. Heterogeneidad entre participantes

El supuesto que más condiciona el rendimiento de FedAvg es que los datos de los participantes sean independientes e idénticamente distribuidos. Cuando no lo son —el caso habitual en la práctica—, los modelos locales divergen entre rondas y el promediado puede degradar el resultado. Li et al. (2020) proponen FedProx para atenuar ese efecto: añaden a la función de pérdida local un término proximal que penaliza el alejamiento respecto de los parámetros globales, limitando la divergencia sin renunciar al entrenamiento local.

Una segunda línea de respuesta a la heterogeneidad consiste en abandonar la idea de un modelo único para todos. Arivazhagan et al. (2019) proponen FedPer, que separa el modelo en una base compartida, entrenada de forma federada, y unas capas de personalización que cada participante entrena solo con sus datos y no comparte. La intuición es que la estructura común se aprende mejor entre todos, mientras que las

particularidades de cada participante se capturan localmente.

2.2.3. Aplicación a la previsión en distribución

La aplicación específica del aprendizaje federado a la previsión de ventas en distribución es todavía un área poco poblada. Long et al. (2025) abordan precisamente este escenario sobre datos minoristas heterogéneos y proponen agrupar a los participantes en conglomerados antes de federar, reconociendo que un único modelo global no se ajusta bien cuando los silos difieren de forma sustancial. Un aspecto metodológico relevante de ese trabajo, y de la práctica habitual del campo, es que la evaluación se realiza particionando un único conjunto de datos real según un eje que genere heterogeneidad, ya que no existen conjuntos públicos con datos de cadenas competidoras reales. Este trabajo sigue esa misma metodología, y sus implicaciones se discuten explícitamente como limitación en el capítulo 6.

2.3. Colaboración con protección de datos

2.3.1. El aprendizaje federado como tecnología de protección de la privacidad

Desde la perspectiva regulatoria, el aprendizaje federado se encuadra en el conjunto de las tecnologías de protección de la privacidad. La Agencia Española de Protección de Datos y el Supervisor Europeo de Protección de Datos le han dedicado un informe conjunto (Agencia Española de Protección de Datos & European Data Protection Supervisor, 2025) en el que reconocen sus ventajas —reducción de la concentración de datos, menor exposición en las transferencias y apoyo al principio de protección de datos desde el diseño— pero introducen una advertencia importante: los parámetros del modelo que se intercambian pueden seguir constituyendo datos personales, ya que son susceptibles de ataques de inferencia, de pertenencia y de inversión del modelo. El informe concluye que el aprendizaje federado no basta por sí solo como medida de anonimización y recomienda complementarlo con privacidad diferencial o agregación segura. Esta observación delimita el alcance de las afirmaciones que pueden hacerse sobre la privacidad del esquema estudiado aquí y se retoma en las líneas de trabajo futuro.

2.3.2. Data clean rooms

La alternativa comercial más extendida para que varias organizaciones exploten datos conjuntos sin intercambiarlos son los *data clean rooms*. Se trata de entornos controlados en los que cada parte aporta sus datos y sobre los que solo pueden ejecutarse consultas o cálculos previamente autorizados, con controles de salida —umbrales mínimos de agregación, supresión de celdas, revisión de resultados— destinados a impedir la reidentificación.

La guía de referencia del sector (IAB Tech Lab, 2024) sistematiza sus principios y delimita sus casos de uso, que se concentran en tres ámbitos: la activación y direccionamiento de audiencias publicitarias, el enriquecimiento y la generación de conocimiento sobre el consumidor, y la medición y optimización de campañas. Su origen y su desarrollo están estrechamente ligados a la publicidad digital, y las principales implantaciones comerciales —entre ellas las de los grandes proveedores de infraestructura de datos (Snowflake Inc., 2026)— reflejan esa orientación.

La comparación detallada entre ambos enfoques, y la discusión de cuál es el primitivo adecuado para el problema que aquí se estudia, se desarrolla en el capítulo 7.

Capítulo 3

Objetivos y preguntas de investigación

3.1. Objetivo general

El objetivo general de este trabajo es determinar, con evidencia empírica y contraste estadístico, si el aprendizaje federado constituye una alternativa útil para la previsión de demanda en distribución alimentaria cuando la centralización de datos no es viable, y cuantificar el valor de negocio que aportaría su adopción.

La formulación es deliberadamente neutra respecto al resultado. El trabajo no parte de la hipótesis de que el aprendizaje federado sea superior, sino de la pregunta de si lo es, y admite como resultado válido que no lo sea.

3.2. Preguntas de investigación

El objetivo general se concreta en cinco preguntas, dos técnicas, dos de negocio y una de alcance ampliado.

RQ1 (técnica). ¿Un modelo federado predice mejor que el modelo local de cada tienda y se aproxima al centralizado, sin compartir datos crudos, en presencia de heterogeneidad entre silos? La pregunta incluye la personalización posterior del modelo federado como variante a evaluar.

RQ2 (técnica). ¿Supera el modelo federado a los métodos convencionales de previsión en distribución, es decir, a los baselines ingenuos, al suavizado exponencial y a los árboles potenciados por gradiente?

RQ3 (negocio). ¿Qué valor económico genera la mejora de precisión atribuible a la colaboración federada, expresado como reducción de error de previsión y traducido a un rango monetario?

RQ4 (negocio). ¿Por qué sería preferible un esquema federado a un *data clean room* para la previsión colaborativa entre operadores que no comparten datos?

RQ5 (ampliación). ¿Qué coste en precisión tendría añadir garantías formales de privacidad mediante privacidad diferencial?

3.3. Objetivos específicos

Para responder a esas preguntas se definen los siguientes objetivos específicos:

1. Construir un conjunto de datos de previsión a partir de un histórico real de ventas de distribución, con una partición temporal que impida la fuga de información y una definición de silos que reproduzca heterogeneidad realista entre participantes.
2. Implementar un modelo de previsión común a todas las condiciones experimentales, de modo que las diferencias observadas sean atribuibles a la forma de entrenamiento y no a la arquitectura.
3. Evaluar cinco condiciones —local, centralizado por silo, centralizado global, federado y federado con personalización— y compararlas entre sí y frente a los métodos convencionales mediante un protocolo único y un contraste estadístico pareado.
4. Desplegar el sistema federado sobre infraestructura distribuida real, con aislamiento efectivo de los datos de cada silo, para verificar que el algoritmo estudiado en simulación se comporta igual fuera de ella.
5. Cuantificar el valor económico de la mejora obtenida y compararlo con la alternativa de los *data clean rooms*.

3.4. Alcance y delimitación

El trabajo se delimita en los siguientes términos. La granularidad de previsión es tienda $\times$ familia de producto $\times$ semana, no referencia individual ni día, por las razones que se detallan en el capítulo 4. El horizonte de evaluación son las ocho últimas semanas

del histórico disponible. El modelo federado se entrena con los silos como participantes, no con las tiendas individuales, lo que corresponde al escenario *cross-silo*.

La pregunta RQ5, relativa al coste en precisión de la privacidad diferencial, se plantea como ampliación y no se aborda experimentalmente en este trabajo; se retoma en las líneas de trabajo futuro del capítulo 9, apoyada en la recomendación regulatoria descrita en el capítulo 2.

Capítulo 4

Materiales y métodos

4.1. Conjunto de datos

Los experimentos se realizan sobre el histórico de ventas de Corporación Favorita, una cadena de distribución ecuatoriana, publicado como conjunto de datos abierto (Kaggle, 2023). Contiene las ventas diarias de 54 tiendas y 33 familias de producto entre 2013 y 2017, junto con ficheros auxiliares de metadatos de tienda, transacciones, precio del petróleo y calendario de festivos.

La elección de este conjunto responde a que reúne tres condiciones poco frecuentes de forma simultánea: es real, es lo bastante grande para entrenar modelos con sentido, y contiene una estructura de tiendas con formatos diferenciados que permite construir silos con heterogeneidad genuina. Su limitación principal, relevante para el capítulo 7, es que no incluye precios ni márgenes: las ventas se expresan en unidades.

4.1.1. Granularidad de la previsión

Se predice a nivel de **tienda** $\times$ **familia de producto** $\times$ **semana**, y no a nivel de referencia individual ni de día. Esta decisión responde a cuatro razones. La granularidad semanal por familia es la que corresponde a las decisiones de reposición agregada y de planificación, que es el uso al que apunta el trabajo. El número de series resultante, 1.782, es manejable para entrenar y evaluar cinco condiciones experimentales de forma repetida. La agregación semanal reduce la intermitencia severa que presentan muchas series diarias a nivel de referencia. Y, por último, el conjunto de datos no contiene precios ni stock por referencia, lo que haría poco fiable una previsión a ese nivel de detalle.

La contrapartida es que los resultados no son directamente extrapolables a la reposición de una referencia concreta, que es un problema distinto y más difícil.

4.1.2. Definición de los silos

Los silos, que son los participantes de la federación, se definen por **formato de tienda** agrupando los tipos originales de la cadena: el silo Grande reúne las 9 tiendas de tipo A, el Mediano las 26 de tipos D y B, y el Pequeño las 19 de tipos E y C. El criterio se eligió tras comparar varias particiones alternativas porque es el que genera mayor heterogeneidad de comportamiento entre silos, y se validó con una segunda métrica independiente —el tráfico de clientes, correlacionado al 0,91 con la venta— para comprobar que la agrupación no era un artefacto de la variable elegida.

Conviene precisar la naturaleza de esta heterogeneidad, porque condiciona la interpretación de los resultados. La mezcla de categorías es bastante homogénea entre formatos; lo que difiere de forma sustancial es la *escala* de venta, con factores de dos a tres veces entre silos, y la *intensidad promocional*. La figura 4.1 muestra esa composición.




Figura 4.1: Reparto de tiendas y de volumen de venta entre los tres silos definidos por formato de tienda. La heterogeneidad entre silos se manifiesta sobre todo en la escala de venta, no en la mezcla de categorías.

4.2. Preparación de los datos

4.2.1. Agregación y variables exógenas

A partir del histórico diario se construye la serie semanal por tienda y familia, sumando las ventas y promediando la intensidad promocional. Se incorporan el precio

semanal del petróleo —relevante en una economía dependiente del crudo como la ecuatoriana—, los festivos nacionales, regionales y locales, y una señal de semana con día de cobro. El tratamiento de los festivos exige cuidado: los registros marcados como transferidos no se observan en la fecha original sino en la de traslado, y las jornadas de recuperación de puente no son festivos a efectos de demanda.

Se recorta además el historial anterior a la apertura de cada tienda, ya que ocho de las 54 abrieron después del inicio del periodo y una de ellas dispone de apenas cuatro meses de datos.

4.2.2. Un problema encontrado en los datos: los huecos de Navidad

Durante la construcción del conjunto se detectó un problema que ilustra la importancia de validar los supuestos sobre los datos. El 25 de diciembre no existe ninguna fila en el histórico original para ninguna tienda ni familia: las tiendas cierran y no se registra siquiera una venta de valor cero. Al descartar las semanas incompletas, esa ausencia deja un hueco interno en el calendario de 1.749 de las 1.782 series.

El problema es que el cálculo de retardos mediante desplazamiento de filas avanza por posición y no por fecha, de modo que un hueco interno desalinea silenciosamente todos los retardos posteriores a cada Navidad. La corrección consistió en reindexar cada serie sobre un calendario semanal completo, marcando los huecos como ausentes, antes de calcular cualquier retardo o media móvil. El conjunto se regeneró con esta corrección y quedó en 322.245 filas. Se añadió además una prueba automática que verifica que ninguna fila del conjunto final queda inmediatamente después de un hueco interno.

4.2.3. Variables predictoras

Cada observación se describe mediante 17 variables continuas y dos identificadores categóricos. Las variables continuas son: los retardos de 1, 2, 4 y 8 semanas, las medias móviles de 4 y 8 semanas y la desviación típica de 4 semanas —todos ellos calculados sobre la escala logarítmica de la venta, y excluyendo la semana en curso para evitar la fuga de información—, la intensidad promocional, el precio del petróleo, la codificación cíclica en seno y coseno de la semana del año y del mes, las tres señales de festivo y la señal de día de cobro. Los identificadores de familia y de tienda se incorporan como variables categóricas destinadas a las capas de *embedding*.

La variable objetivo es el logaritmo de la venta semanal, transformación adecuada

dada la distribución fuertemente asimétrica de las ventas y la presencia del pico atípico asociado al terremoto de abril de 2016.

Las variables continuas se estandarizan mediante puntuación z , con medias y desviaciones calculadas *exclusivamente* sobre el conjunto de entrenamiento, para no filtrar información de validación ni de prueba.

4.2.4. Partición temporal

La partición es de tipo *walk-forward*, respetando estrictamente el orden cronológico, como corresponde a un problema de series temporales. El conjunto de entrenamiento abarca 220 semanas, desde el 7 de enero de 2013 hasta el 17 de abril de 2017; el de validación, las 8 semanas siguientes, hasta el 12 de junio de 2017; y el de prueba, las 8 últimas, hasta el 7 de agosto de 2017. Se excluyen las semanas incompletas, que representan un 2,55 % de las filas. La figura 4.2 representa el esquema.




Figura 4.2: Partición temporal empleada. El orden cronológico se respeta estrictamente: la validación es posterior al entrenamiento y la prueba, posterior a la validación.

El conjunto final contiene 322.245 filas, repartidas en 293.997 de entrenamiento, 13.992 de validación y 14.256 de prueba. La validación cubre 53 de las 54 tiendas: la que abrió en abril de 2017 no tiene todavía historial suficiente en ese tramo.

4.2.5. Ceros estructurales por falta de surtido

Un segundo aspecto de los datos merece mención explícita porque afecta a la interpretación de los resultados. No todas las tiendas venden todas las familias: 779 de las 1.749 series con historial —un 45 %— presentan un prefijo de más de cuatro semanas con venta nula al inicio del periodo de entrenamiento. No se trata de demanda no atendida sino de ausencia de surtido, y en ocasiones se extiende a casi todo el periodo, como sucede con familias de textil o libros en tiendas de proximidad.

Estos ceros son datos legítimos y no se eliminan: la combinación tienda $\times$ familia existe siempre en el conjunto, con venta cero cuando no hay surtido. El modelo, que dispone de los retardos y las medias móviles de cada serie, aprende a predecir valores

próximos a cero en esos casos, que es la respuesta correcta. La distinción importa, sin embargo, para los métodos que estiman de forma explícita tendencia y estacionalidad sobre la serie completa: en el suavizado exponencial, ese prefijo de ceros distorsionaba gravemente la estimación inicial y obligó a recortarlo antes del ajuste.

4.3. Modelo de previsión

Todas las condiciones experimentales comparten la misma arquitectura, de modo que las diferencias observadas sean atribuibles a la forma de entrenamiento y no al modelo. Se trata de un perceptrón multicapa con *embeddings* de entidad, representado en la figura 4.3.




Figura 4.3: Arquitectura del perceptrón multicapa con *embeddings* de entidad, común a las cinco condiciones experimentales: 4.985 parámetros en total.

Los *embeddings* permiten que el modelo aprenda una representación densa de cada familia y de cada tienda en lugar de tratarlas como variables indicadoras dispersas, lo que resulta especialmente útil en el escenario federado: la tabla de *embeddings* es compartida, de modo que una familia poco frecuente en un silo se beneficia de lo aprendido en los silos donde sí es habitual.

El entrenamiento emplea la función de pérdida de Huber, robusta frente a valores atípicos como el pico del terremoto de 2016, y el optimizador Adam, con parada temprana sobre el conjunto de validación. El modelo tiene 4.985 parámetros, un tamaño deliberadamente reducido: en aprendizaje federado el coste de comunicación es proporcional al número de parámetros que se intercambian en cada ronda.

4.4. Diseño experimental

Se comparan cinco condiciones que difieren únicamente en qué datos entrenan el modelo y cómo:

- A — Local.** Un modelo independiente por tienda, entrenado solo con sus propios datos. Es el punto de partida sin colaboración: lo que cada operador podría hacer por su cuenta.
- B — Centralizado por silo.** Un modelo por silo, entrenado con los datos de todas las tiendas de ese formato. Representa la centralización interna de un operador.
- C — Centralizado global.** Un único modelo con los datos de los tres silos juntos. Corresponde al escenario que la literatura suele tomar como techo de rendimiento y que en la práctica sería inviable entre competidores.
- D — Federado.** Los tres silos entrenan mediante FedAvg, sin compartir datos crudos. Se evalúa también FedProx como variante para heterogeneidad.
- E — Federado con personalización.** Se parte de los pesos del modelo federado y se realiza un ajuste fino por tienda con sus propios datos.

La figura 4.4 representa el esquema de una ronda federada. Es importante notar que los participantes son los tres silos, no las 54 tiendas: cada silo centraliza internamente sus propias tiendas, lo cual es legítimo porque corresponde a un mismo operador. La personalización por tienda de la condición E es un ajuste posterior a la convergencia, no un nivel adicional de federación.




Figura 4.4: Una ronda de FedAvg: el coordinador envía los parámetros del modelo global, cada silo entrena localmente unas pocas épocas y devuelve los parámetros resultantes, que se promedian ponderando por el número de filas de cada silo. Los datos permanecen siempre en el silo.

Como referencia externa se evalúan además cuatro métodos convencionales: los baselines ingenuos de persistencia y estacional de 52 semanas, la media móvil de 4 semanas, el suavizado exponencial ETS/Holt-Winters ajustado serie a serie, y un modelo LightGBM global con los identificadores de tienda y familia como variables categóricas. Este último se incluye como referencia clásica no federada de máxima exigencia; no se federa, porque el promediado de parámetros de FedAvg opera sobre pesos de redes neuronales y no tiene equivalente directo en un conjunto de árboles.

4.5. Métricas y contraste estadístico

La métrica principal es el WMAPE (*weighted mean absolute percentage error*), definido para cada serie como el cociente entre la suma de los errores absolutos y la suma de las ventas reales. Se elige frente al MAPE porque las ventas incluyen ceros y valores muy pequeños, ante los cuales el MAPE se vuelve inestable. Se reportan además el MASE y el RMSSE, que escalan el error respecto al de un método ingenuo sobre el propio historial de la serie.

Las métricas se calculan por serie y se agregan por la *mediana*, no por la media, para que un puñado de series con error extremo —habituales en familias de demanda intermitente— no domine la comparación. Se reporta también la cobertura, es decir, la proporción de series para las que cada método produce una previsión válida.

Las diferencias entre métodos se contrastan mediante el test de Wilcoxon de rangos con signo pareado por serie, que no asume normalidad de las diferencias. Dado que se realizan ocho contrastes sobre los mismos datos, se aplica la corrección de Holm-Bonferroni para controlar la tasa de error por familia de comparaciones.

4.6. Infraestructura

La experimentación se realiza con Flower, un marco específico para aprendizaje federado, en su versión 1.32.1. Los experimentos de las condiciones D y E se ejecutan primero con su motor de simulación, que reproduce los participantes como procesos dentro de una misma máquina, lo que permite iterar con rapidez.

Dado que ese modo no verifica que el esquema funcione sobre infraestructura realmente distribuida, el sistema se desplegó además sobre tres máquinas virtuales independientes en Microsoft Azure, cada una con los datos de un único silo. Los detalles y los resultados de ese despliegue se describen en el capítulo 5.

Todo el código, los datos derivados y los resultados intermedios se gestionan en un repositorio con control de versiones, con pruebas automatizadas, integración continua y versionado de datos, según se detalla en el appendix A.

Capítulo 5

Resultados

Pendiente de redacción.

Capítulo 6

Discusión

Pendiente de redacción.

Capítulo 7

Análisis de negocio

Pendiente de redacción.

Capítulo 8

Presupuesto

Pendiente de redacción.

Capítulo 9

Conclusiones y líneas futuras

Pendiente de redacción.

Bibliografía

- Agencia Española de Protección de Datos & European Data Protection Supervisor. (2025). *TechDispatch: Aprendizaje federado* (TechDispatch N.º 1). AEPD y EDPS. <https://www.aepd.es/guias/tech-dispatch-aprendizaje-federado.pdf>
- Arivazhagan, M. G., Aggarwal, V., Singh, A. K., & Choudhary, S. (2019). *Federated learning with personalization layers*. <https://arxiv.org/abs/1912.00818>
- IAB Tech Lab. (2024, julio). *Data Clean Rooms: Guidance and Recommended Practices* (Guidance). IAB Technology Laboratory. <https://iabtechlab.com/datacleanrooms/>
- Kaggle. (2023). *Store Sales — Time Series Forecasting* [Conjunto de datos]. Consultado el 9 de julio de 2026, desde <https://www.kaggle.com/competitions/store-sales-time-series-forecasting>
- Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems*, 2, 429-450. <https://arxiv.org/abs/1812.06127>
- Long, Y., Xu, L., Zheng, G., & Brintrup, A. (2025). *PA-CFL: Privacy-adaptive clustered federated learning for transformer-based sales forecasting on heterogeneous retail data*. <https://arxiv.org/abs/2503.12220>
- McMahan, B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). Communication-efficient learning of deep networks from decentralized data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 1273-1282. <https://proceedings.mlr.press/v54/mcmahan17a.html>
- Petropoulos, F., Grushka-Cockayne, Y., Siemsen, E., & Spiliotis, E. (2024). Wielding Occam’s razor: Fast and frugal retail forecasting. *Journal of the Operational Research Society*. <https://doi.org/10.1080/01605682.2024.2421339>
- Snowflake Inc. (2026). *Data clean rooms*. Consultado el 14 de julio de 2026, desde <https://www.snowflake.com/en/product/features/data-clean-rooms/>

Apéndice A

Anexos

Pendiente de redacción.