

TECNUN — UNIVERSIDAD DE NAVARRA
Escuela de Ingeniería

Proyecto Fin de Máster

ANÁLISIS DE DATOS EN INGENIERÍA

Aprendizaje federado para la previsión de demanda en retail: evaluación frente a modelos locales, centralizados y convencionales

Alessandro Flammia
Donostia-San Sebastián, septiembre de 2026

Resumen

La previsión de demanda mejora cuando el modelo se entrena con más datos, pero los operadores de distribución que competirían por esos datos no pueden compartirlos. El aprendizaje federado propone una salida: entrenar un modelo conjunto intercambiando parámetros en lugar de datos. Este trabajo evalúa si esa promesa se sostiene empíricamente en la previsión de ventas de un supermercado.

Sobre un histórico real de 54 tiendas y 33 familias de producto, agregado a nivel semanal, se comparan cinco condiciones —modelo local por tienda, centralizado por silo, centralizado global, federado y federado con personalización— entre sí y frente a cuatro métodos convencionales de previsión, con idéntica partición temporal, idéntico protocolo de evaluación y contraste estadístico de todas las diferencias mediante el test de Wilcoxon pareado con corrección por comparaciones múltiples.

Los resultados contradicen la hipótesis de partida en dos puntos. El modelo centralizado, que la literatura suele tomar como techo de rendimiento, resulta ser el peor de los cinco: la precisión empeora de forma monótona a medida que se agregan datos de tiendas heterogéneas en un modelo de capacidad limitada. Y el modelo federado, por sí solo, es significativamente peor que el modelo local; es la personalización posterior por tienda la que lo convierte en la mejor de las cinco condiciones, con un WMAPE de 0,1379 frente a 0,1476 del modelo local. Frente a los métodos no federados, el balance es más matizado: la mejor condición federada supera por muy poco a una media móvil de cuatro semanas y queda un 3,95 % por detrás de un modelo LightGBM entrenado sobre datos agrupados, diferencia que el contraste confirma como real.

El sistema se desplegó además sobre tres máquinas virtuales independientes en la nube, con aislamiento efectivo de los datos de cada silo, verificando que el comportamiento observado en simulación se mantiene sobre infraestructura distribuida.

En el plano económico, la colaboración federada reduce un 16,50 % el error de previsión ponderado por volumen respecto a que cada tienda entrene en solitario, lo que se traduce en un ahorro anual estimado de entre 0,5 y 3,9 millones de euros para la red analizada. El beneficio, sin embargo, se concentra en las series de mayor volumen y

casi la mitad de las series empeoran, lo que aconseja seleccionar el modelo serie a serie. Se argumenta finalmente que, para la tarea concreta de entrenar un modelo predictivo entre partes que no ceden datos, el aprendizaje federado es un primitivo más adecuado que un *data clean room*, sin presentarlos como alternativas excluyentes.

Palabras clave: aprendizaje federado, previsión de demanda, distribución comercial, datos no IID, personalización de modelos, MLOps.

Abstract

Demand forecasting improves when models are trained on more data, yet retailers who compete for that data cannot share it. Federated learning offers a way out: training a joint model by exchanging parameters instead of raw data. This work evaluates whether that promise holds empirically for supermarket sales forecasting.

Using a real sales history of 54 stores and 33 product families aggregated weekly, five conditions —per-store local model, per-silo centralised, globally centralised, federated, and federated with personalisation— are compared against each other and against four conventional forecasting methods, under an identical temporal split, an identical evaluation protocol, and paired Wilcoxon testing with correction for multiple comparisons.

The results contradict the initial hypothesis on two counts. The centralised model, usually treated in the literature as the performance ceiling, turns out to be the worst of the five: accuracy degrades monotonically as heterogeneous store data are pooled into a capacity-limited model. And the federated model on its own is significantly worse than the local one; it is the subsequent per-store personalisation that makes it the best of the five conditions, reaching a WMAPE of 0.1379 against 0.1476 for the local model. Against non-federated methods the picture is more nuanced: the best federated condition only marginally outperforms a four-week moving average and falls 3.95 % short of a LightGBM model trained on pooled data, a gap the statistical test confirms as real.

The system was additionally deployed across three independent cloud virtual machines with effective per-silo data isolation, confirming that the behaviour observed in simulation carries over to distributed infrastructure.

Economically, federated collaboration reduces volume-weighted forecast error by 16.50 % relative to each store training alone, which translates into an estimated annual saving of between 0.5 and 3.9 million euros for the network studied. The benefit is, however, concentrated in high-volume series and almost half of the series get worse, which argues for selecting the model series by series. Finally, it is argued that for the specific

task of training a predictive model across parties that do not share data, federated learning is a more suitable primitive than a data clean room, without presenting the two as mutually exclusive.

Keywords: federated learning, demand forecasting, retail, non-IID data, model personalisation, MLOps.

Agradecimientos

A Idoia Ochoa, por dirigir este trabajo y por reorientarlo cuando hacía falta. La decisión de no quedarse en la comparación técnica y exigirle al proyecto una justificación de negocio cambió el alcance de la memoria para bien.

A mi familia, por el apoyo durante todo el máster.

A Tecnun y a sus profesores, por la formación que hay detrás de este trabajo.

Índice general

Resumen	i
Abstract	iii
Agradecimientos	v
1. Introducción	1
1.1. Contexto	1
1.2. El aprendizaje federado como alternativa	2
1.3. Motivación y enfoque	2
1.4. Aportaciones	3
1.5. Estructura del documento	4
2. Estado del arte	5
2.1. Previsión de demanda en distribución	5
2.2. Aprendizaje federado	6
2.2.1. Formulación básica	6
2.2.2. Heterogeneidad entre participantes	6
2.2.3. Aplicación a la previsión en distribución	7
2.3. Colaboración con protección de datos	7
2.3.1. El aprendizaje federado como tecnología de protección de la privacidad	7
2.3.2. Data clean rooms	8
3. Objetivos y preguntas de investigación	9

3.1. Objetivo general	9
3.2. Preguntas de investigación	9
3.3. Objetivos específicos	10
3.4. Alcance y delimitación	10
4. Materiales y métodos	12
4.1. Conjunto de datos	12
4.1.1. Granularidad de la previsión	12
4.1.2. Definición de los silos	13
4.2. Preparación de los datos	13
4.2.1. Agregación y variables exógenas	13
4.2.2. Un problema encontrado en los datos: los huecos de Navidad . .	14
4.2.3. Variables predictoras	14
4.2.4. Partición temporal	15
4.2.5. Ceros estructurales por falta de surtido	15
4.3. Modelo de previsión	16
4.4. Diseño experimental	17
4.5. Métricas y contraste estadístico	18
4.6. Infraestructura	18
5. Resultados	20
5.1. Comparación general	20
5.2. Las cinco condiciones experimentales	21
5.2.1. Convergencia del entrenamiento federado	22
5.3. Contraste estadístico	23
5.4. Ajuste de hiperparámetros	25
5.5. Despliegue distribuido	27
6. Discusión	28
6.1. Por qué centralizar empeora el modelo	28
6.2. Por qué el federado necesita personalización	29

6.3.	Por qué el ajuste de hiperparámetros no se propagó	29
6.4.	Por qué falló la corrección de sesgo	30
6.5.	El federado frente a los métodos no federados	30
6.6.	Limitaciones	31
6.6.1.	Los silos no son operadores competidores reales	31
6.6.2.	Ausencia de precios y de márgenes	31
6.6.3.	Alcance temporal y de validación	31
6.6.4.	Privacidad	31
7.	Análisis de negocio	33
7.1.	Valor económico de la colaboración (RQ3)	33
7.1.1.	Qué comparación tiene sentido económico	33
7.1.2.	Separación entre lo medido y lo supuesto	33
7.1.3.	La parte física: unidades de error evitadas	34
7.1.4.	Robustez: de dónde procede el ahorro	34
7.1.5.	La parte monetaria	35
7.2.	Aprendizaje federado frente a <i>data clean rooms</i> (RQ4)	37
7.2.1.	Comparación estructurada	37
7.2.2.	Argumento	38
7.2.3.	Matización necesaria	38
8.	Presupuesto	40
8.1.	Coste de personal	40
8.2.	Coste de equipos	41
8.3.	Coste de software y servicios en la nube	41
8.4.	Resumen del presupuesto	42
9.	Conclusiones y líneas futuras	43
9.1.	Respuesta a las preguntas de investigación	43
9.2.	Conclusiones generales	45
9.3.	Líneas futuras	45

Bibliografía 47**A. Anexos** 48

A.1. Repositorio y reproducibilidad 48

A.2. Cuaderno de laboratorio 49

A.3. Dificultades del despliegue en la nube 49

A.4. Cuadro de mando de resultados 50

Índice de figuras

1.1. El obstáculo a la centralización de datos entre operadores	2
4.1. Composición de los silos	13
4.2. Partición temporal <i>walk-forward</i>	15
4.3. Arquitectura del modelo	16
4.4. Esquema de una ronda de entrenamiento federado	17
5.1. Comparación de métodos por WMAPE	21
5.2. Distribución del error por serie	22
5.3. Convergencia del entrenamiento federado	23
5.4. Tamaño de efecto y significación de los contrastes	24
5.5. Búsqueda de arquitectura	26
5.6. Despliegue distribuido en Azure	27
7.1. Concentración del ahorro entre series	35
7.2. Sensibilidad del ahorro anual estimado	36

Índice de tablas

5.1. Comparación de los métodos evaluados	20
5.2. Contraste de Wilcoxon entre métodos	24
7.1. Comparación entre aprendizaje federado y <i>data clean rooms</i>	37
8.1. Coste de personal	40
8.2. Coste de equipos	41
8.3. Coste de software y servicios	41
8.4. Resumen del presupuesto	42

Capítulo 1

Introducción

1.1. Contexto

La previsión de demanda es una de las decisiones con más consecuencias operativas en la distribución alimentaria. De ella dependen los pedidos a proveedor, la asignación de espacio en lineal y la planificación de personal, y sus errores se materializan en dos costes de signo opuesto: si la previsión se queda corta se produce una rotura de stock, con pérdida de venta y de margen; si se pasa, el excedente acaba en merma, especialmente en las categorías perecederas. En el comercio de alimentación europeo se estima que entre el 5 % y el 7 % de los productos perecederos se desecha, y los perecederos representan aproximadamente la mitad de la venta de un supermercado. Con márgenes netos del sector en torno al 2 %, una mejora moderada de la precisión de la previsión tiene un efecto apreciable sobre el resultado.

La calidad de un modelo de previsión depende en buena medida del volumen y la variedad de datos con los que se entrena. Una tienda aislada dispone de un histórico limitado; un modelo entrenado con los datos de muchas tiendas puede aprender patrones —estacionalidad, efecto de las promociones, comportamiento de los festivos— que en una serie individual quedan ocultos por el ruido. Esta observación empuja de forma natural hacia la centralización de datos.

El problema es que esa centralización no siempre es posible. Dentro de una misma cadena, juntar los datos de sus tiendas es una decisión interna sin obstáculos. Entre operadores distintos, en cambio, los datos de venta a nivel de tienda y producto son información comercial sensible: revelan la estructura de surtido, la posición competitiva y la respuesta a las promociones. A la reticencia competitiva se suma el marco normativo europeo, que impone principios de minimización y limitación de la finalidad sobre los

datos personales que puedan estar implicados. El resultado es una situación paradójica: los operadores que más se beneficiarían de un modelo conjunto son precisamente los que no pueden construirlo por la vía habitual.




Figura 1.1: La vía habitual para mejorar un modelo de previsión —juntar los datos de todos los participantes en un repositorio común— no está disponible cuando los participantes compiten entre sí: los datos de venta por tienda y producto son información comercial sensible.

1.2. El aprendizaje federado como alternativa

El aprendizaje federado propone invertir el flujo habitual: en lugar de mover los datos hacia el modelo, mueve el modelo hacia los datos. Cada participante entrena localmente con su propia información y envía a un coordinador únicamente los parámetros resultantes; el coordinador los promedia y devuelve un modelo agregado que incorpora lo aprendido por todos sin que ninguno haya cedido un solo registro. La formulación de referencia de este esquema es el algoritmo *Federated Averaging* (McMahan et al., 2017).

Sobre el papel, esto encaja con el problema descrito: permitiría a varios operadores construir un modelo conjunto de previsión conservando sus datos. La pregunta que este trabajo se plantea es si ese encaje conceptual se sostiene empíricamente, es decir, si un modelo federado predice mejor que el que cada operador podría entrenar por su cuenta, y cómo se sitúa frente a las alternativas realmente disponibles en la práctica, incluidos los métodos convencionales de previsión que se utilizan a diario en el sector.

1.3. Motivación y enfoque

Buena parte de la literatura de aprendizaje federado evalúa el método frente al escenario centralizado ideal, dando por supuesto que este último constituye el techo de rendimiento alcanzable. Ese marco deja fuera dos comprobaciones que resultan decisivas para justificar su adopción en un caso real. La primera es la comparación con métodos convencionales sencillos: si una media móvil de cuatro semanas iguala el rendimiento de

una arquitectura federada, la complejidad adicional es difícil de defender. La segunda es la cuantificación del beneficio económico, sin la cual no hay criterio para decidir si compensa montar la infraestructura.

Este trabajo adopta por tanto un enfoque doble, técnico y de negocio. En el plano técnico compara cinco condiciones experimentales —local, centralizado por silo, centralizado global, federado y federado con personalización— entre sí y frente a cuatro métodos convencionales de previsión, sobre un mismo conjunto de datos, una misma partición temporal y un mismo protocolo de evaluación, con contraste estadístico de todas las diferencias. En el plano de negocio traduce la mejora obtenida a unidades de error evitadas y, a partir de ahí, a un rango de ahorro económico, y compara el aprendizaje federado con la alternativa comercial más extendida para la colaboración entre empresas que no comparten datos, los *data clean rooms*.

1.4. Aportaciones

Las aportaciones principales de este trabajo son cuatro.

En primer lugar, una comparación homogénea y estadísticamente contrastada de trece métodos de previsión sobre el mismo problema, que sitúa al aprendizaje federado en un marco realista en vez de compararlo únicamente contra el escenario centralizado.

En segundo lugar, la identificación y documentación de tres resultados que contradicen la intuición de partida del proyecto: que centralizar datos de tiendas heterogéneas empeora el modelo en lugar de mejorarlo; que el aprendizaje federado por sí solo rinde peor que el modelo local, siendo la personalización posterior la que lo vuelve competitivo; y que un ajuste de hiperparámetros que beneficia claramente a una etapa del proceso puede perjudicar a la siguiente.

En tercer lugar, un despliegue real del sistema federado sobre tres máquinas independientes en la nube, con aislamiento efectivo de los datos de cada silo, que traslada el experimento desde el entorno de simulación a una infraestructura distribuida.

Por último, un modelo de cuantificación económica que separa de forma explícita lo que se deriva de los datos propios de lo que depende de supuestos externos, y que incorpora un análisis de robustez sobre la distribución del beneficio.

1.5. Estructura del documento

El capítulo 2 revisa el estado del arte en previsión de demanda en distribución, aprendizaje federado y tecnologías de colaboración con protección de datos. El capítulo 3 formula los objetivos y las preguntas de investigación. El capítulo 4 describe los datos, su preparación, el modelo empleado, el diseño experimental y la infraestructura. El capítulo 5 presenta los resultados, incluido el contraste estadístico y el despliegue distribuido. El capítulo 6 los interpreta y expone las limitaciones del estudio. El capítulo 7 aborda las dos preguntas de negocio: la cuantificación del valor y la comparación con los *data clean rooms*. El capítulo 8 recoge el presupuesto del proyecto y el capítulo 9, las conclusiones y las líneas de trabajo futuro.

Capítulo 2

Estado del arte

Este capítulo revisa los tres cuerpos de literatura sobre los que se apoya el trabajo: los métodos de previsión de demanda empleados en distribución, el aprendizaje federado y sus variantes para datos heterogéneos, y las tecnologías de colaboración entre organizaciones que no comparten datos, donde se sitúan tanto el propio aprendizaje federado como los *data clean rooms*.

2.1. Previsión de demanda en distribución

La previsión de ventas en distribución tiene características que la separan de otros problemas de series temporales. El número de series es muy elevado —el producto de tiendas por categorías o referencias—, muchas de ellas son cortas, intermitentes o con ceros estructurales, y las señales relevantes son en buena medida exógenas: promociones, festividades, calendario de cobro y estacionalidad anual.

Los métodos clásicos siguen siendo la referencia de partida. Los modelos ingenuos —la persistencia, que repite el último valor observado, y el estacional, que repite el valor de la misma semana del año anterior— proporcionan el suelo de comparación mínimo. El suavizado exponencial en su formulación de espacio de estados, habitualmente designado como ETS, y los modelos de la familia Holt-Winters añaden tendencia y estacionalidad de forma explícita, y durante décadas han constituido el estándar operativo del sector.

La irrupción de los métodos de aprendizaje automático, y en particular de los árboles potenciados por gradiente, ha desplazado parcialmente ese estándar en las competiciones de previsión. Sin embargo, la evidencia más reciente matiza el entusiasmo: Petropoulos et al. (2024) muestran que en previsión minorista los métodos sencillos y de bajo coste computacional resultan sorprendentemente competitivos frente a alternativas mucho

más complejas, y advierten de que la ganancia marginal de la sofisticación es menor de lo que se suele suponer. Esta observación es directamente pertinente para este trabajo, y motiva la decisión de incluir baselines convencionales en la comparación en lugar de contrastar el modelo federado únicamente contra otras variantes de red neuronal.

2.2. Aprendizaje federado

2.2.1. Formulación básica

El aprendizaje federado fue formulado por McMahan et al. (2017) para entrenar modelos sobre datos distribuidos en dispositivos sin centralizarlos. El algoritmo de referencia, *Federated Averaging* (FedAvg), procede por rondas: el servidor envía los parámetros del modelo global a los participantes; cada uno entrena unas pocas épocas con sus datos locales; el servidor recibe los parámetros resultantes y los promedia ponderando por el número de muestras de cada participante. El proceso se repite hasta convergencia. El dato crudo no abandona en ningún momento al participante.

La literatura distingue dos escenarios según la naturaleza de los participantes. En el federado *cross-device* los participantes son muchos dispositivos con pocos datos cada uno y disponibilidad intermitente. En el federado *cross-silo*, que es el que corresponde a este trabajo, los participantes son pocas organizaciones con volúmenes grandes de datos y disponibilidad estable.

2.2.2. Heterogeneidad entre participantes

El supuesto que más condiciona el rendimiento de FedAvg es que los datos de los participantes sean independientes e idénticamente distribuidos. Cuando no lo son —el caso habitual en la práctica—, los modelos locales divergen entre rondas y el promediado puede degradar el resultado. Li et al. (2020) proponen FedProx para atenuar ese efecto: añaden a la función de pérdida local un término proximal que penaliza el alejamiento respecto de los parámetros globales, limitando la divergencia sin renunciar al entrenamiento local.

Una segunda línea de respuesta a la heterogeneidad consiste en abandonar la idea de un modelo único para todos. Arivazhagan et al. (2019) proponen FedPer, que separa el modelo en una base compartida, entrenada de forma federada, y unas capas de personalización que cada participante entrena solo con sus datos y no comparte. La intuición es que la estructura común se aprende mejor entre todos, mientras que las

particularidades de cada participante se capturan localmente.

2.2.3. Aplicación a la previsión en distribución

La aplicación específica del aprendizaje federado a la previsión de ventas en distribución es todavía un área poco poblada. Long et al. (2025) abordan precisamente este escenario sobre datos minoristas heterogéneos y proponen agrupar a los participantes en conglomerados antes de federar, reconociendo que un único modelo global no se ajusta bien cuando los silos difieren de forma sustancial. Un aspecto metodológico relevante de ese trabajo, y de la práctica habitual del campo, es que la evaluación se realiza particionando un único conjunto de datos real según un eje que genere heterogeneidad, ya que no existen conjuntos públicos con datos de cadenas competidoras reales. Este trabajo sigue esa misma metodología, y sus implicaciones se discuten explícitamente como limitación en el capítulo 6.

2.3. Colaboración con protección de datos

2.3.1. El aprendizaje federado como tecnología de protección de la privacidad

Desde la perspectiva regulatoria, el aprendizaje federado se encuadra en el conjunto de las tecnologías de protección de la privacidad. La Agencia Española de Protección de Datos y el Supervisor Europeo de Protección de Datos le han dedicado un informe conjunto (Agencia Española de Protección de Datos & European Data Protection Supervisor, 2025) en el que reconocen sus ventajas —reducción de la concentración de datos, menor exposición en las transferencias y apoyo al principio de protección de datos desde el diseño— pero introducen una advertencia importante: los parámetros del modelo que se intercambian pueden seguir constituyendo datos personales, ya que son susceptibles de ataques de inferencia, de pertenencia y de inversión del modelo. El informe concluye que el aprendizaje federado no basta por sí solo como medida de anonimización y recomienda complementarlo con privacidad diferencial o agregación segura. Esta observación delimita el alcance de las afirmaciones que pueden hacerse sobre la privacidad del esquema estudiado aquí y se retoma en las líneas de trabajo futuro.

2.3.2. Data clean rooms

La alternativa comercial más extendida para que varias organizaciones exploten datos conjuntos sin intercambiarlos son los *data clean rooms*. Se trata de entornos controlados en los que cada parte aporta sus datos y sobre los que solo pueden ejecutarse consultas o cálculos previamente autorizados, con controles de salida —umbrales mínimos de agregación, supresión de celdas, revisión de resultados— destinados a impedir la reidentificación.

La guía de referencia del sector (IAB Tech Lab, 2024) sistematiza sus principios y delimita sus casos de uso, que se concentran en tres ámbitos: la activación y direccionamiento de audiencias publicitarias, el enriquecimiento y la generación de conocimiento sobre el consumidor, y la medición y optimización de campañas. Su origen y su desarrollo están estrechamente ligados a la publicidad digital, y las principales implantaciones comerciales —entre ellas las de los grandes proveedores de infraestructura de datos (Snowflake Inc., 2026)— reflejan esa orientación.

La comparación detallada entre ambos enfoques, y la discusión de cuál es el primitivo adecuado para el problema que aquí se estudia, se desarrolla en el capítulo 7.

Capítulo 3

Objetivos y preguntas de investigación

3.1. Objetivo general

El objetivo general de este trabajo es determinar, con evidencia empírica y contraste estadístico, si el aprendizaje federado constituye una alternativa útil para la previsión de demanda en distribución alimentaria cuando la centralización de datos no es viable, y cuantificar el valor de negocio que aportaría su adopción.

La formulación es deliberadamente neutra respecto al resultado. El trabajo no parte de la hipótesis de que el aprendizaje federado sea superior, sino de la pregunta de si lo es, y admite como resultado válido que no lo sea.

3.2. Preguntas de investigación

El objetivo general se concreta en cinco preguntas, dos técnicas, dos de negocio y una de alcance ampliado.

RQ1 (técnica). ¿Un modelo federado predice mejor que el modelo local de cada tienda y se aproxima al centralizado, sin compartir datos crudos, en presencia de heterogeneidad entre silos? La pregunta incluye la personalización posterior del modelo federado como variante a evaluar.

RQ2 (técnica). ¿Supera el modelo federado a los métodos convencionales de previsión en distribución, es decir, a los baselines ingenuos, al suavizado exponencial y a los árboles potenciados por gradiente?

RQ3 (negocio). ¿Qué valor económico genera la mejora de precisión atribuible a la colaboración federada, expresado como reducción de error de previsión y traducido a un rango monetario?

RQ4 (negocio). ¿Por qué sería preferible un esquema federado a un *data clean room* para la previsión colaborativa entre operadores que no comparten datos?

RQ5 (ampliación). ¿Qué coste en precisión tendría añadir garantías formales de privacidad mediante privacidad diferencial?

3.3. Objetivos específicos

Para responder a esas preguntas se definen los siguientes objetivos específicos:

1. Construir un conjunto de datos de previsión a partir de un histórico real de ventas de distribución, con una partición temporal que impida la fuga de información y una definición de silos que reproduzca heterogeneidad realista entre participantes.
2. Implementar un modelo de previsión común a todas las condiciones experimentales, de modo que las diferencias observadas sean atribuibles a la forma de entrenamiento y no a la arquitectura.
3. Evaluar cinco condiciones —local, centralizado por silo, centralizado global, federado y federado con personalización— y compararlas entre sí y frente a los métodos convencionales mediante un protocolo único y un contraste estadístico pareado.
4. Desplegar el sistema federado sobre infraestructura distribuida real, con aislamiento efectivo de los datos de cada silo, para verificar que el algoritmo estudiado en simulación se comporta igual fuera de ella.
5. Cuantificar el valor económico de la mejora obtenida y compararlo con la alternativa de los *data clean rooms*.

3.4. Alcance y delimitación

El trabajo se delimita en los siguientes términos. La granularidad de previsión es tienda $\times$ familia de producto $\times$ semana, no referencia individual ni día, por las razones que se detallan en el capítulo 4. El horizonte de evaluación son las ocho últimas semanas

del histórico disponible. El modelo federado se entrena con los silos como participantes, no con las tiendas individuales, lo que corresponde al escenario *cross-silo*.

La pregunta RQ5, relativa al coste en precisión de la privacidad diferencial, se plantea como ampliación y no se aborda experimentalmente en este trabajo; se retoma en las líneas de trabajo futuro del capítulo 9, apoyada en la recomendación regulatoria descrita en el capítulo 2.

Capítulo 4

Materiales y métodos

4.1. Conjunto de datos

Los experimentos se realizan sobre el histórico de ventas de Corporación Favorita, una cadena de distribución ecuatoriana, publicado como conjunto de datos abierto (Kaggle, 2023). Contiene las ventas diarias de 54 tiendas y 33 familias de producto entre 2013 y 2017, junto con ficheros auxiliares de metadatos de tienda, transacciones, precio del petróleo y calendario de festivos.

La elección de este conjunto responde a que reúne tres condiciones poco frecuentes de forma simultánea: es real, es lo bastante grande para entrenar modelos con sentido, y contiene una estructura de tiendas con formatos diferenciados que permite construir silos con heterogeneidad genuina. Su limitación principal, relevante para el capítulo 7, es que no incluye precios ni márgenes: las ventas se expresan en unidades.

4.1.1. Granularidad de la previsión

Se predice a nivel de **tienda $\times$ familia de producto $\times$ semana**, y no a nivel de referencia individual ni de día. Esta decisión responde a cuatro razones. La granularidad semanal por familia es la que corresponde a las decisiones de reposición agregada y de planificación, que es el uso al que apunta el trabajo. El número de series resultante, 1.782, es manejable para entrenar y evaluar cinco condiciones experimentales de forma repetida. La agregación semanal reduce la intermitencia severa que presentan muchas series diarias a nivel de referencia. Y, por último, el conjunto de datos no contiene precios ni stock por referencia, lo que haría poco fiable una previsión a ese nivel de detalle.

La contrapartida es que los resultados no son directamente extrapolables a la reposición de una referencia concreta, que es un problema distinto y más difícil.

4.1.2. Definición de los silos

Los silos, que son los participantes de la federación, se definen por **formato de tienda** agrupando los tipos originales de la cadena: el silo Grande reúne las 9 tiendas de tipo A, el Mediano las 26 de tipos D y B, y el Pequeño las 19 de tipos E y C. El criterio se eligió tras comparar varias particiones alternativas porque es el que genera mayor heterogeneidad de comportamiento entre silos, y se validó con una segunda métrica independiente —el tráfico de clientes, correlacionado al 0,91 con la venta— para comprobar que la agrupación no era un artefacto de la variable elegida.

Conviene precisar la naturaleza de esta heterogeneidad, porque condiciona la interpretación de los resultados. La mezcla de categorías es bastante homogénea entre formatos; lo que difiere de forma sustancial es la *escala* de venta, con factores de dos a tres veces entre silos, y la *intensidad promocional*. La figura 4.1 muestra esa composición.




Figura 4.1: Reparto de tiendas y de volumen de venta entre los tres silos definidos por formato de tienda. La heterogeneidad entre silos se manifiesta sobre todo en la escala de venta, no en la mezcla de categorías.

4.2. Preparación de los datos

4.2.1. Agregación y variables exógenas

A partir del histórico diario se construye la serie semanal por tienda y familia, sumando las ventas y promediando la intensidad promocional. Se incorporan el precio

semanal del petróleo —relevante en una economía dependiente del crudo como la ecuatoriana—, los festivos nacionales, regionales y locales, y una señal de semana con día de cobro. El tratamiento de los festivos exige cuidado: los registros marcados como transferidos no se observan en la fecha original sino en la de traslado, y las jornadas de recuperación de puente no son festivos a efectos de demanda.

Se recorta además el historial anterior a la apertura de cada tienda, ya que ocho de las 54 abrieron después del inicio del periodo y una de ellas dispone de apenas cuatro meses de datos.

4.2.2. Un problema encontrado en los datos: los huecos de Navidad

Durante la construcción del conjunto se detectó un problema que ilustra la importancia de validar los supuestos sobre los datos. El 25 de diciembre no existe ninguna fila en el histórico original para ninguna tienda ni familia: las tiendas cierran y no se registra siquiera una venta de valor cero. Al descartar las semanas incompletas, esa ausencia deja un hueco interno en el calendario de 1.749 de las 1.782 series.

El problema es que el cálculo de retardos mediante desplazamiento de filas avanza por posición y no por fecha, de modo que un hueco interno desalinea silenciosamente todos los retardos posteriores a cada Navidad. La corrección consistió en reindexar cada serie sobre un calendario semanal completo, marcando los huecos como ausentes, antes de calcular cualquier retardo o media móvil. El conjunto se regeneró con esta corrección y quedó en 322.245 filas. Se añadió además una prueba automática que verifica que ninguna fila del conjunto final queda inmediatamente después de un hueco interno.

4.2.3. Variables predictoras

Cada observación se describe mediante 17 variables continuas y dos identificadores categóricos. Las variables continuas son: los retardos de 1, 2, 4 y 8 semanas, las medias móviles de 4 y 8 semanas y la desviación típica de 4 semanas —todos ellos calculados sobre la escala logarítmica de la venta, y excluyendo la semana en curso para evitar la fuga de información—, la intensidad promocional, el precio del petróleo, la codificación cíclica en seno y coseno de la semana del año y del mes, las tres señales de festivo y la señal de día de cobro. Los identificadores de familia y de tienda se incorporan como variables categóricas destinadas a las capas de *embedding*.

La variable objetivo es el logaritmo de la venta semanal, transformación adecuada

dada la distribución fuertemente asimétrica de las ventas y la presencia del pico atípico asociado al terremoto de abril de 2016.

Las variables continuas se estandarizan mediante puntuación z , con medias y desviaciones calculadas *exclusivamente* sobre el conjunto de entrenamiento, para no filtrar información de validación ni de prueba.

4.2.4. Partición temporal

La partición es de tipo *walk-forward*, respetando estrictamente el orden cronológico, como corresponde a un problema de series temporales. El conjunto de entrenamiento abarca 220 semanas, desde el 7 de enero de 2013 hasta el 17 de abril de 2017; el de validación, las 8 semanas siguientes, hasta el 12 de junio de 2017; y el de prueba, las 8 últimas, hasta el 7 de agosto de 2017. Se excluyen las semanas incompletas, que representan un 2,55 % de las filas. La figura 4.2 representa el esquema.




Figura 4.2: Partición temporal empleada. El orden cronológico se respeta estrictamente: la validación es posterior al entrenamiento y la prueba, posterior a la validación.

El conjunto final contiene 322.245 filas, repartidas en 293.997 de entrenamiento, 13.992 de validación y 14.256 de prueba. La validación cubre 53 de las 54 tiendas: la que abrió en abril de 2017 no tiene todavía historial suficiente en ese tramo.

4.2.5. Ceros estructurales por falta de surtido

Un segundo aspecto de los datos merece mención explícita porque afecta a la interpretación de los resultados. No todas las tiendas venden todas las familias: 779 de las 1.749 series con historial —un 45 %— presentan un prefijo de más de cuatro semanas con venta nula al inicio del periodo de entrenamiento. No se trata de demanda no atendida sino de ausencia de surtido, y en ocasiones se extiende a casi todo el periodo, como sucede con familias de textil o libros en tiendas de proximidad.

Estos ceros son datos legítimos y no se eliminan: la combinación tienda $\times$ familia existe siempre en el conjunto, con venta cero cuando no hay surtido. El modelo, que dispone de los retardos y las medias móviles de cada serie, aprende a predecir valores

próximos a cero en esos casos, que es la respuesta correcta. La distinción importa, sin embargo, para los métodos que estiman de forma explícita tendencia y estacionalidad sobre la serie completa: en el suavizado exponencial, ese prefijo de ceros distorsionaba gravemente la estimación inicial y obligó a recortarlo antes del ajuste.

4.3. Modelo de previsión

Todas las condiciones experimentales comparten la misma arquitectura, de modo que las diferencias observadas sean atribuibles a la forma de entrenamiento y no al modelo. Se trata de un perceptrón multicapa con *embeddings* de entidad, representado en la figura 4.3.




Figura 4.3: Arquitectura del perceptrón multicapa con *embeddings* de entidad, común a las cinco condiciones experimentales: 4.985 parámetros en total.

Los *embeddings* permiten que el modelo aprenda una representación densa de cada familia y de cada tienda en lugar de tratarlas como variables indicadoras dispersas, lo que resulta especialmente útil en el escenario federado: la tabla de *embeddings* es compartida, de modo que una familia poco frecuente en un silo se beneficia de lo aprendido en los silos donde sí es habitual.

El entrenamiento emplea la función de pérdida de Huber, robusta frente a valores atípicos como el pico del terremoto de 2016, y el optimizador Adam, con parada temprana sobre el conjunto de validación. El modelo tiene 4.985 parámetros, un tamaño deliberadamente reducido: en aprendizaje federado el coste de comunicación es proporcional al número de parámetros que se intercambian en cada ronda.

4.4. Diseño experimental

Se comparan cinco condiciones que difieren únicamente en qué datos entrenan el modelo y cómo:

- A — Local.** Un modelo independiente por tienda, entrenado solo con sus propios datos. Es el punto de partida sin colaboración: lo que cada operador podría hacer por su cuenta.
- B — Centralizado por silo.** Un modelo por silo, entrenado con los datos de todas las tiendas de ese formato. Representa la centralización interna de un operador.
- C — Centralizado global.** Un único modelo con los datos de los tres silos juntos. Corresponde al escenario que la literatura suele tomar como techo de rendimiento y que en la práctica sería inviable entre competidores.
- D — Federado.** Los tres silos entrenan mediante FedAvg, sin compartir datos crudos. Se evalúa también FedProx como variante para heterogeneidad.
- E — Federado con personalización.** Se parte de los pesos del modelo federado y se realiza un ajuste fino por tienda con sus propios datos.

La figura 4.4 representa el esquema de una ronda federada. Es importante notar que los participantes son los tres silos, no las 54 tiendas: cada silo centraliza internamente sus propias tiendas, lo cual es legítimo porque corresponde a un mismo operador. La personalización por tienda de la condición E es un ajuste posterior a la convergencia, no un nivel adicional de federación.




Figura 4.4: Una ronda de FedAvg: el coordinador envía los parámetros del modelo global, cada silo entrena localmente unas pocas épocas y devuelve los parámetros resultantes, que se promedian ponderando por el número de filas de cada silo. Los datos permanecen siempre en el silo.

Como referencia externa se evalúan además cuatro métodos convencionales: los baselines ingenuos de persistencia y estacional de 52 semanas, la media móvil de 4 semanas, el suavizado exponencial ETS/Holt-Winters ajustado serie a serie, y un modelo LightGBM global con los identificadores de tienda y familia como variables categóricas. Este último se incluye como referencia clásica no federada de máxima exigencia; no se federa, porque el promediado de parámetros de FedAvg opera sobre pesos de redes neuronales y no tiene equivalente directo en un conjunto de árboles.

4.5. Métricas y contraste estadístico

La métrica principal es el WMAPE (*weighted mean absolute percentage error*), definido para cada serie como el cociente entre la suma de los errores absolutos y la suma de las ventas reales. Se elige frente al MAPE porque las ventas incluyen ceros y valores muy pequeños, ante los cuales el MAPE se vuelve inestable. Se reportan además el MASE y el RMSSE, que escalan el error respecto al de un método ingenuo sobre el propio historial de la serie.

Las métricas se calculan por serie y se agregan por la *mediana*, no por la media, para que un puñado de series con error extremo —habituales en familias de demanda intermitente— no domine la comparación. Se reporta también la cobertura, es decir, la proporción de series para las que cada método produce una previsión válida.

Las diferencias entre métodos se contrastan mediante el test de Wilcoxon de rangos con signo pareado por serie, que no asume normalidad de las diferencias. Dado que se realizan ocho contrastes sobre los mismos datos, se aplica la corrección de Holm-Bonferroni para controlar la tasa de error por familia de comparaciones.

4.6. Infraestructura

La experimentación se realiza con Flower, un marco específico para aprendizaje federado, en su versión 1.32.1. Los experimentos de las condiciones D y E se ejecutan primero con su motor de simulación, que reproduce los participantes como procesos dentro de una misma máquina, lo que permite iterar con rapidez.

Dado que ese modo no verifica que el esquema funcione sobre infraestructura realmente distribuida, el sistema se desplegó además sobre tres máquinas virtuales independientes en Microsoft Azure, cada una con los datos de un único silo. Los detalles y los resultados de ese despliegue se describen en el capítulo 5.

Todo el código, los datos derivados y los resultados intermedios se gestionan en un repositorio con control de versiones, con pruebas automatizadas, integración continua y versionado de datos, según se detalla en el appendix A.

Capítulo 5

Resultados

Todos los resultados de este capítulo se refieren al conjunto de prueba —las ocho últimas semanas del histórico—, que no interviene en ningún momento del ajuste ni de la selección de modelos. Las métricas se agregan por la mediana de las series, y la cobertura indica la proporción de series para las que el método produce una previsión.

5.1. Comparación general

La tabla 5.1 recoge el rendimiento de los trece métodos evaluados y la figura 5.1 los ordena visualmente.

Tabla 5.1: Rendimiento en el conjunto de prueba de los métodos evaluados, ordenados por WMAPE. Las tres métricas se agregan por la mediana de las series.

Método	WMAPE	MASE	RMSSE	Cobertura
LightGBM global	0,1320	0,7749	0,6300	100,0 %
Media móvil (4 sem.)	0,1379	0,8672	0,7023	99,1 %
E — Federado + person.	0,1379	0,9019	0,7234	98,1 %
A — Local	0,1476	0,9283	0,7501	98,1 %
D — Federado (FedAvg)	0,1507	1,0100	0,7966	100,0 %
Persistencia ($t - 1$)	0,1584	0,9742	0,8025	99,8 %
B — Centralizado por silo	0,1676	1,0423	0,8256	100,0 %
C — Centralizado global	0,1736	1,1317	0,8832	100,0 %
Estacional ($t - 52$)	0,2296	1,2684	1,0215	98,1 %
ETS/Holt-Winters	0,3344	1,4553	1,1883	95,2 %




Figura 5.1: Los métodos evaluados ordenados por WMAPE en el conjunto de prueba. Las condiciones federadas se destacan en azul y el mejor método no federado, en naranja.

Tres lecturas se desprenden de inmediato. La primera es que el mejor método del estudio no es ninguna de las condiciones federadas, sino un LightGBM global entrenado sobre los datos agrupados de todas las tiendas. La segunda es que la media móvil de cuatro semanas, el más simple de los métodos evaluados, iguala en mediana a la mejor condición federada; esta coincidencia se examina en detalle en la sección 5.3, porque el contraste pareado matiza la aparente igualdad. La tercera es que el suavizado exponencial queda muy por detrás del resto, un resultado esperable en series con demanda intermitente y ceros estructurales.

5.2. Las cinco condiciones experimentales

Aislando las cinco condiciones del diseño experimental se obtiene una ordenación que contradice la hipótesis de partida:

C — Centralizado global	0,1736
B — Centralizado por silo	0,1676
A — Local	0,1476
D — Federado	0,1507
E — Federado + personalización	0,1379

El resultado más llamativo es que **el rendimiento empeora de forma monótona a medida que se centralizan más datos**: el modelo global (C), que dispone de aproximadamente 54 veces más datos de entrenamiento que cualquier modelo local, es el peor de los cinco. Se comprobó que no se trata de un problema de entrenamiento insuficiente: aumentar la paciencia de la parada temprana en el silo de mayor tamaño solo produce sobreajuste, con la pérdida de validación alcanzando el mismo mínimo y subiendo después.

El segundo resultado relevante es que el modelo federado por sí solo (D, 0,1507) no alcanza al modelo local (A, 0,1476). Es la personalización posterior (E, 0,1379) la que convierte al esquema federado en la mejor de las cinco condiciones. Dicho de otro modo: en este problema, federar sin personalizar no compensa.

La figura 5.2 muestra que estas diferencias de mediana conviven con una dispersión considerable entre series, lo que anticipa que la mejora no es uniforme.




Figura 5.2: Distribución del WMAPE por serie. Las cajas abarcan el rango intercuartílico y la línea interior es la mediana; los bigotes se recortan en el eje para conservar la legibilidad de la zona informativa. La diferencia entre condiciones es pequeña frente a la variabilidad entre series.

5.2.1. Convergencia del entrenamiento federado

La figura 5.3 muestra la evolución de la pérdida de validación a lo largo de las rondas para cuatro configuraciones federadas. La convergencia es muy rápida: el grueso del aprendizaje se produce en las dos o tres primeras rondas, y a partir de ahí la pérdida

oscila sin mejorar de forma sostenida. Esto tiene una consecuencia práctica favorable, ya que el coste de comunicación —proporcional al número de rondas— es bajo.

Se observa también que aumentar el número de épocas locales por ronda perjudica: con tres épocas la pérdida se vuelve visiblemente más inestable. La explicación es coherente con la teoría del método: cuantas más épocas locales, más se alejan los modelos de cada silo entre sincronizaciones, y más daño hace el promediado posterior.




Figura 5.3: Pérdida de validación centralizada por ronda para cuatro configuraciones. Se omite la ronda 0, que corresponde a la inicialización aleatoria y comprimiría la escala. El aprendizaje se concentra en las primeras rondas.

5.3. Contraste estadístico

Las diferencias anteriores se contrastan mediante el test de Wilcoxon pareado por serie, con corrección de Holm-Bonferroni para las ocho comparaciones. La tabla 5.2 y la figura 5.4 recogen los resultados. Todos los contrastes resultan significativos al nivel del 5 % incluso después de la corrección.

Tabla 5.2: Contraste de Wilcoxon de rangos con signo, pareado por serie sobre el WMAPE en prueba. Δ es la variación de la mediana del segundo método respecto al primero; un valor negativo indica que el segundo método es mejor. Los p-valores incorporan la corrección de Holm-Bonferroni.

Contraste	n	Δ	p (Holm)
A — Local <i>vs</i> C — Centralizado global	1.655	+17,64 %	$4,2 \cdot 10^{-61}$
A — Local <i>vs</i> B — Centralizado por silo	1.655	+12,29 %	$1,6 \cdot 10^{-23}$
A — Local <i>vs</i> D — Federado	1.655	+1,89 %	$8,0 \cdot 10^{-22}$
E <i>vs</i> Media móvil	1.655	+0,74 %	$1,6 \cdot 10^{-3}$
E <i>vs</i> LightGBM global	1.655	-3,95 %	$1,5 \cdot 10^{-47}$
A — Local <i>vs</i> E — Federado + person.	1.655	-6,57 %	$3,5 \cdot 10^{-2}$
D — Federado <i>vs</i> E — Federado + person.	1.655	-8,31 %	$3,9 \cdot 10^{-47}$
C — Centralizado global <i>vs</i> D — Federado	1.686	-13,21 %	$2,4 \cdot 10^{-34}$




Figura 5.4: Variación de la mediana del WMAPE en cada contraste, con el p-valor corregido. Todos los contrastes son significativos, pero los tamaños de efecto varían en un orden de magnitud.

Cuatro conclusiones se derivan del contraste:

1. **La escalera de centralización es real.** Que B y C sean peores que A no es una fluctuación: son los dos contrastes con los p-valores más pequeños de todo el estudio.

2. **El federado sin personalizar es significativamente peor que el local.** La diferencia entre A y D, aunque modesta en magnitud (+1,89%), es muy consistente entre series.
3. **La personalización es lo que hace competitivo al federado.** El contraste D *vs* E combina un tamaño de efecto apreciable (−8,31 %) con una significación muy alta.
4. **El valor de colaborar es real, pero es el efecto más débil.** El contraste A *vs* E, que es el que sustenta el análisis económico del capítulo 7, mejora un 6,57 % y resulta significativo, pero con $p = 0,035$ queda apenas por debajo del umbral tras la corrección. Es, con diferencia, el contraste menos robusto de los ocho, y así debe interpretarse.

Merece una nota aparte la comparación entre E y la media móvil. En las medianas globales de la tabla 5.1 ambos métodos dan 0,1379, lo que sugiere un empate. Sin embargo, esas medianas se calculan sobre conjuntos de series distintos, ya que la cobertura de ambos métodos no coincide. Sobre las 1.655 series *comunes*, que es lo que compara el test pareado, la condición E resulta mejor de forma estadísticamente significativa, si bien el tamaño del efecto es pequeño (0,74 %). El test pareado es la comparación metodológicamente correcta, y así se adopta aquí.

Por el contrario, la ventaja de LightGBM sobre la mejor condición federada —un 3,95 %— no puede atribuirse al azar en modo alguno.

5.4. Ajuste de hiperparámetros

Ninguna de las condiciones A–E había pasado por un ajuste de hiperparámetros propio, a diferencia del LightGBM de referencia. Para descartar que la desventaja del esquema federado se debiera simplemente a esa asimetría, se realizó una búsqueda aleatoria de arquitectura y parámetros de optimización sobre un proxy rápido: un único entrenamiento sobre los datos agrupados, seleccionando por WMAPE en validación.

La búsqueda encontró una configuración claramente mejor que la original en ese proxy —0,1093 frente a 0,1880, una mejora del 41,9 %—, con una red más ancha, tasa de aprendizaje mayor y menos regularización (figura 5.5).




Figura 5.5: Resultado de la búsqueda aleatoria de arquitectura sobre el proxy agrupado. El primer candidato evaluado es siempre la arquitectura original, para disponer de una comparación limpia.

Esa mejora se trasladó parcialmente a la condición federada: con la nueva arquitectura, la mejor configuración de D pasó de 0,1507 a 0,1402, una mejora de aproximadamente el 7 % confirmada en el conjunto de prueba. Se observó además que con la tasa de aprendizaje más alta, tres épocas locales por ronda degradan gravemente el resultado (0,2786), lo que refuerza la lectura de la figura 5.3.

Sin embargo, esa mejora **no se propagó a la condición E**. Ninguna de las tres variantes de personalización probadas sobre el modelo D mejorado —ajuste fino completo, ajuste con tasa de aprendizaje reducida y ajuste al estilo de FedPer congelando las capas compartidas— superó al resultado original: la mejor de ellas obtuvo 0,1446 frente a los 0,1379 de la configuración original. La interpretación de este resultado se aborda en el capítulo 6.

Se evaluó por último una corrección del sesgo de retransformación que introduce el uso de la escala logarítmica, mediante el estimador de *smearing* (Duan, 1983), calculado por tienda. El resultado fue muy desfavorable: el WMAPE pasó de 0,1446 a 0,8876. El diagnóstico es que con apenas unos cientos de filas de entrenamiento por tienda, el factor de corrección —una media de exponenciales de los residuos— resulta extremadamente sensible a los valores atípicos, y llegó a alcanzar valores de 7,41 en algunas tiendas cuando debería situarse próximo a la unidad. La corrección se descartó.

5.5. Despliegue distribuido

Los resultados anteriores se obtuvieron con el motor de simulación de Flower, que representa a los tres silos como procesos dentro de una misma máquina. Para verificar que el esquema funciona sobre infraestructura realmente distribuida, se desplegó el sistema sobre tres máquinas virtuales independientes en Microsoft Azure, según el esquema de la figura 5.6.




Figura 5.6: Arquitectura del despliegue. Cada máquina contiene únicamente el conjunto de datos de su silo; el agregador se aloja en una de ellas y solo maneja parámetros y un conjunto de validación de referencia.

El despliegue exigió pasar del motor de simulación al motor de despliegue de Flower, con un coordinador y tres nodos comunicándose por gRPC. Antes de provisionar la infraestructura se verificó que la nueva aplicación reproducía la trayectoria de pérdida por ronda del código de simulación, de modo que cualquier diferencia posterior fuera atribuible a la infraestructura y no al algoritmo.

El aislamiento de datos se comprobó de forma directa: en cada máquina de silo, el directorio de datos contiene exclusivamente el fichero de ese silo. La federación completó tanto una corrida de FedAvg como una de FedProx, y la pérdida de validación evolucionó desde aproximadamente 4,9 en la inicialización aleatoria hasta el entorno de 0,05 hacia la tercera o quinta ronda, la misma trayectoria observada en simulación. El modelo global resultante quedó registrado en el registro de modelos de Azure ML, con la mejor ronda en la número 7.

Este ejercicio no busca mejorar la precisión —el algoritmo es el mismo—, sino demostrar que el esquema es implantable sobre infraestructura real con aislamiento efectivo de los datos. Las dificultades encontradas durante el despliegue, que resultan informativas por sí mismas, se recogen en el appendix A.

Capítulo 6

Discusión

6.1. Por qué centralizar empeora el modelo

El resultado que más se aparta de la intuición es la ordenación $A < B < C$: cuantos más datos se agregan en un único modelo, peor predice. Conviene subrayar que no es un problema de subentrenamiento, ya que se descartó explícitamente aumentando la paciencia de la parada temprana sin obtener mejora alguna.

La explicación coherente con lo observado en los datos es la heterogeneidad entre tiendas. Como se describió en el capítulo 4, los silos difieren sobre todo en escala de venta —con factores de dos a tres— y en intensidad promocional. Un modelo único con capacidad limitada —4.985 parámetros— debe repartir esa capacidad entre comportamientos que no son intercambiables, y acaba aprendiendo un compromiso que no sirve bien a ninguno. El modelo local, en cambio, dedica toda su capacidad a una única tienda.

Este razonamiento sugiere que la ordenación observada no es una propiedad universal, sino el resultado de la relación entre la capacidad del modelo, el volumen de datos por entidad y el grado de heterogeneidad. Un modelo con mucha mayor capacidad podría absorber la heterogeneidad en lugar de promediarla. De hecho, el LightGBM global —que es precisamente un modelo global sobre datos agrupados— es el mejor método del estudio, lo que apoya esa lectura: no es la agregación de datos lo que perjudica, sino la agregación con un modelo cuya capacidad no da para representar las diferencias.

6.2. Por qué el federado necesita personalización

La condición D hereda el problema de C: FedAvg construye un modelo único para todos los participantes, y por tanto está sujeto a la misma tensión. Que D (0,1507) resulte mejor que C (0,1736) pero peor que A (0,1476) encaja bien en esa lectura. El promediado federado actúa como una regularización que impide que el modelo se especialice en ningún silo, lo que lo protege frente al compromiso extremo de C pero no lo hace competitivo frente a un modelo dedicado.

La personalización resuelve exactamente esa carencia: parte de un punto de inicio que ya ha capturado la estructura compartida entre silos —estacionalidad, efecto de festivos, comportamiento de las familias— y dedica un ajuste corto a las particularidades de cada tienda. El contraste D *vs* E, que es uno de los más fuertes del estudio, confirma que ese es el mecanismo que hace funcionar al esquema.

Esta observación coincide con la motivación de FedPer (Arivazhagan et al., 2019) y con la línea de trabajo de Long et al. (2025), que también renuncian al modelo único cuando los participantes son suficientemente distintos.

6.3. Por qué el ajuste de hiperparámetros no se propagó

El ajuste de arquitectura mejoró de forma clara el proxy agrupado y la condición D, pero perjudicó a la condición E. La hipótesis más consistente con el diseño del experimento es un desajuste entre la capacidad del modelo y el volumen de datos disponible en cada etapa del proceso.

La arquitectura ganadora es sensiblemente más ancha que la original. Esa capacidad adicional es provechosa mientras el modelo se entrena con las cerca de 294.000 filas agregadas de los tres silos, que es el caso del proxy y del entrenamiento federado. En la etapa de personalización, en cambio, cada modelo se ajusta con apenas unos cientos de filas de una única tienda, y una red más ancha sobreajusta con más facilidad. El ajuste óptimo para una etapa resulta así perjudicial para la siguiente.

La consecuencia metodológica es que en un proceso por etapas los hiperparámetros no deberían optimizarse de forma aislada sobre una sola de ellas. Una búsqueda específica y más contenida para la etapa de personalización es una línea natural de continuación que este trabajo no ha explorado.

6.4. Por qué falló la corrección de sesgo

El fracaso de la corrección de *smearing* tiene una explicación estadística directa. El factor de Duan es la media de la exponencial de los residuos; la exponencial amplifica de forma desproporcionada los residuos grandes, de modo que con muestras pequeñas unos pocos valores atípicos bastan para disparar el factor. Al calcularlo por tienda, sobre unos cientos de observaciones, la estimación resultó inestable, con valores hasta 7,41 cuando lo esperable en un modelo bien calibrado es un valor próximo a uno.

La corrección no es errónea como concepto —el sesgo de retransformación que pretende corregir es real—, sino que fue mal aplicada al estimarla sobre muestras demasiado pequeñas. Calcular un factor único global sobre el conjunto agregado promediaría mejor los atípicos y es una posibilidad razonable, que se deja anotada como trabajo futuro sin afirmar que vaya a funcionar.

6.5. El federado frente a los métodos no federados

El resultado más incómodo para la tesis del trabajo es que el mejor método sigue siendo un LightGBM global, con una ventaja de casi el 4 % que el contraste estadístico confirma como real. Dos consideraciones matizan su alcance sin negarlo.

La primera es de aplicabilidad. El LightGBM global requiere reunir los datos crudos de todas las tiendas en un mismo lugar. Dentro de una cadena eso es viable, y en ese caso la recomendación de este trabajo sería usar LightGBM y no un esquema federado. Entre operadores que compiten, que es el escenario que motiva el trabajo, esa opción no está sobre la mesa; la comparación pertinente pasa a ser entonces con la condición A, que es lo que cada operador podría hacer en solitario.

La segunda es de naturaleza del modelo. Los árboles potenciados por gradiente siguen siendo muy competitivos en datos tabulares, y además no se prestan al promediado de parámetros en que se basa FedAvg: no existe una operación equivalente a promediar pesos entre dos conjuntos de árboles. Federar un modelo de esa familia exigiría esquemas distintos, lo que constituye una limitación estructural del enfoque y no un defecto de la implementación.

Conviene también situar el resultado frente a la literatura: la observación de Petropoulos et al. (2024) de que los métodos sencillos son sorprendentemente competitivos en previsión minorista se ve confirmada aquí de forma clara, ya que una media móvil de cuatro semanas compite de tú a tú con toda la maquinaria federada.

6.6. Limitaciones

6.6.1. Los silos no son operadores competidores reales

La limitación más importante del estudio es que los tres silos son formatos de tienda de una misma cadena, no empresas distintas. Se trata de la metodología estándar del campo, ya que no existen conjuntos de datos públicos con ventas de cadenas competidoras, y es la misma que emplean los trabajos de referencia en el área. Pero implica que la heterogeneidad reproducida, aunque real, es probablemente menor que la que existiría entre operadores distintos, con políticas de surtido, precios y promociones propias. Cabe esperar que en un escenario real la ventaja de la personalización fuera mayor y la del modelo global menor, pero es una expectativa razonada, no un resultado medido.

6.6.2. Ausencia de precios y de márgenes

El conjunto de datos expresa las ventas en unidades y no contiene precios ni márgenes. Esto obliga a que toda la traducción económica del capítulo 7 descansa en parámetros externos, y explica que sus resultados se presenten como rangos y no como cifras puntuales. Además, algunas familias se venden por peso, de modo que la magnitud «unidad» no es homogénea entre categorías.

6.6.3. Alcance temporal y de validación

La evaluación se realiza sobre un único horizonte de ocho semanas y un único corte temporal. Una validación con varios orígenes de previsión —desplazando repetidamente la ventana— daría una estimación más estable de las diferencias, y es una mejora natural que este trabajo no incorpora.

6.6.4. Privacidad

El esquema implementado protege los datos en el sentido de que estos no abandonan el silo, lo que se verificó de forma efectiva en el despliegue distribuido. No incorpora, sin embargo, garantías formales de privacidad. Como advierten la AEPD y el EDPS (Agencia Española de Protección de Datos & European Data Protection Supervisor, 2025), los parámetros intercambiados pueden seguir siendo datos personales y ser vulnerables a ataques de inferencia, por lo que el aprendizaje federado por sí solo

no constituye una medida de anonimización. Las afirmaciones de este trabajo sobre privacidad deben entenderse limitadas a la no cesión de datos crudos. Añadir privacidad diferencial o agregación segura, y medir su coste en precisión, es la pregunta RQ5 que queda abierta.

Por último, el despliegue en la nube se realizó sin cifrado del canal entre los nodos, al discurrir el tráfico por una red privada virtual. Un despliegue en producción debería habilitarlo.

Capítulo 7

Análisis de negocio

Este capítulo responde a las dos preguntas de negocio del trabajo: cuánto vale la mejora obtenida (RQ3) y por qué el aprendizaje federado sería preferible a un *data clean room* para este problema (RQ4).

7.1. Valor económico de la colaboración (RQ3)

7.1.1. Qué comparación tiene sentido económico

La comparación relevante para la decisión de negocio no es la del modelo federado frente al mejor método del estudio, sino frente a lo que cada operador podría hacer por su cuenta. Un operador que no puede acceder a los datos de sus competidores tiene dos opciones: entrenar en solitario (condición A) o participar en una federación y personalizar el resultado (condición E). La diferencia entre ambas es el valor de colaborar, y es la que se cuantifica aquí.

Se descarta deliberadamente anclar el análisis en el LightGBM global. Aunque sea el mejor método, requiere reunir datos crudos de todas las tiendas, que es precisamente lo que el escenario excluye. Usarlo como referencia produciría un resultado engañoso, favorable o desfavorable según cómo se plantee.

7.1.2. Separación entre lo medido y lo supuesto

El conjunto de datos no contiene precios ni márgenes. Para evitar que el resultado dependa de forma opaca de supuestos externos, el modelo separa explícitamente dos partes:

- La **parte física** —cuántas unidades de error se evitan— se deriva íntegramente de los resultados del trabajo, sin ningún parámetro externo.
- La **parte monetaria** —cuánto cuesta cada unidad de error— usa parámetros de sector y se presenta siempre como un rango con análisis de sensibilidad.

Esta separación permite que el lector acepte la primera parte aunque discrepe de la segunda.

7.1.3. La parte física: unidades de error evitadas

El error se agrega ponderando por volumen y no por la mediana de las series. La razón es que el dinero sigue al volumen: una serie que vende 10.000 unidades pesa mucho más en la cuenta de resultados que una que vende diez. Para cada serie se reconstruye el error absoluto en unidades a partir de su WMAPE y de sus ventas reales en el periodo de prueba.

Sobre las 1.655 series comunes a ambas condiciones, que suman 46,0 millones de unidades vendidas en las ocho semanas de prueba, el error absoluto agregado pasa de 4,90 millones de unidades en la condición A a 4,09 millones en la condición E. Se evitan por tanto **807.857 unidades de error en ocho semanas**, lo que equivale a una reducción del **16,50 %** del error total.

Conviene detenerse en este número, porque difiere sustancialmente del 6,57 % de mejora en la mediana por serie que recoge el capítulo 5. Ambos son correctos y miden cosas distintas: la mediana describe a la serie típica, mientras que el agregado ponderado describe el efecto sobre el conjunto del negocio. Que el segundo sea muy superior indica que la personalización mejora especialmente en las series de mayor volumen, lo cual es favorable desde el punto de vista económico.

7.1.4. Robustez: de dónde procede el ahorro

Antes de traducir esa cifra a euros conviene comprobar si es un efecto general o descansa en unos pocos casos. La respuesta, que figura en la figura 7.1, obliga a matizar el resultado.




Figura 7.1: Porcentaje acumulado del ahorro total según las series ordenadas de mayor a menor aportación. La curva supera el 100 % y desciende después, porque a partir de cierto punto las series restan en lugar de sumar.

El ahorro está muy concentrado: las 10 series con mayor aportación explican el 37,5 % del total y las 50 primeras, el 84,6 %. Más relevante todavía, **en 764 de las 1.655 series —un 46,2 %— la condición E resulta peor que la condición A**, con un coste conjunto de 207.493 unidades que ya está descontado del ahorro neto. A nivel de tienda el balance es positivo en 40 de las 53.

La lectura honesta es, por tanto, que la colaboración federada produce un beneficio agregado apreciable, impulsado por las series de mayor volumen, pero que no mejora de forma uniforme y perjudica a casi la mitad de las series. Esto es coherente con que el contraste A *vs* E fuera el más débil de los ocho.

De aquí se deriva además una recomendación operativa: una implantación real debería decidir por serie, sobre el conjunto de validación, si conviene usar el modelo personalizado o el local, en lugar de aplicar la personalización de forma indiscriminada. Esa selección capturaría el beneficio y evitaría el perjuicio. No se ha implementado ni validado en este trabajo, y se propone como línea de continuación.

7.1.5. La parte monetaria

Para traducir las unidades a euros se emplea el siguiente razonamiento. Una unidad mal prevista acaba, o bien en exceso de inventario que en categorías perecederas termina en merma —perdiéndose el coste del producto—, o bien en una rotura de stock,

perdiéndose el margen de la venta no realizada. Sin el desglose entre sobreprevisión e infraprevisión, se adopta el supuesto neutral de promediar ambos costes.

Tres parámetros se recorren en el análisis de sensibilidad. El **margen bruto** del comercio de alimentación, que las referencias del sector sitúan en torno al 21–22 % de la venta, se recorre entre el 18 y el 26 %. La **fracción del error que llega a generar coste** —el resto lo absorben el stock de seguridad, la reposición intradía o el propio surtido— se recorre entre el 20 y el 50 %. Y el **valor medio de la unidad vendida**, que es el parámetro más incierto por ausencia de precios en los datos, se recorre entre 1 y 3 €.

Anualizando las 807.857 unidades del periodo de prueba, el resultado se muestra en la figura 7.2.




Figura 7.2: Ahorro anual estimado para el conjunto de las 54 tiendas, con margen bruto fijado en el 22 %, en función de los dos parámetros más inciertos.

El rango completo del análisis va de 0,53 a 3,94 millones de euros anuales para el conjunto de la red. El escenario central —margen del 22 %, un 35 % del error con coste asociado y un valor unitario de 2 €— arroja **aproximadamente 1,84 millones de euros anuales**, del orden de 35.000 € por tienda y año.

Estas cifras deben leerse como un orden de magnitud, no como una estimación precisa. Su valor está en indicar que el beneficio potencial es lo bastante grande como para justificar el coste de montar la infraestructura, que según el capítulo 8 es de un orden inferior.

7.2. Aprendizaje federado frente a *data clean rooms* (RQ4)

Los *data clean rooms* son hoy la alternativa comercial más extendida para que varias organizaciones exploten datos conjuntos sin intercambiarlos, y por tanto la comparación natural para el enfoque propuesto.

7.2.1. Comparación estructurada

La tabla 7.1 contrasta ambos enfoques en las dimensiones relevantes para este problema.

Tabla 7.1: Comparación de ambos enfoques en las dimensiones relevantes para la previsión colaborativa de demanda.

Dimensión	<i>Data clean room</i>	Aprendizaje federado
Tarea que resuelve	Consultas y cálculos autorizados sobre datos ya existentes	Entrenamiento de un modelo predictivo nuevo
Movimiento de datos	Los datos se copian a un entorno común controlado	Los datos no salen de cada participante
Tercero de confianza	Necesario: alguien opera el entorno	No necesario para custodiar datos; el coordinador solo maneja parámetros
Casos de uso maduros	Audiencias publicitarias, enriquecimiento y medición de campañas	Modelos predictivos entre silos
Madurez del <i>tooling</i>	Alta, con oferta comercial consolidada	Menor, con marcos abiertos en evolución
Encaje normativo	Controles de salida y umbrales de agregación	Minimización por diseño, pero los parámetros pueden seguir siendo datos personales

7.2.2. Argumento

La diferencia decisiva no es de nivel de protección sino de **naturaleza de la tarea**. Un *data clean room* está diseñado para responder preguntas sobre datos que ya existen: cuántos clientes comparten dos empresas, qué solapamiento tienen dos audiencias, qué efecto tuvo una campaña. La guía de referencia del sector (IAB Tech Lab, 2024) recoge precisamente esos tres ámbitos —activación de audiencias, enriquecimiento y medición— como sus casos de uso.

El problema de este trabajo es de otra clase: no se trata de consultar datos existentes sino de **construir un modelo predictivo** cuyo entrenamiento requiere múltiples pasadas iterativas sobre los datos de todos los participantes. Podría en principio ejecutarse dentro de un *clean room*, pero eso exigiría que todos los participantes depositasen sus datos crudos en el entorno de un tercero, que es exactamente la cesión que se quería evitar. El aprendizaje federado invierte el planteamiento: lo que circula son los parámetros, y el dato permanece en origen.

A ello se añade una consideración práctica en el escenario de competidores directos. Un *clean room* exige acordar quién lo opera, con qué garantías y bajo qué contrato; el consenso sobre ese tercero es a menudo el verdadero obstáculo. En un esquema federado el coordinador no custodia datos, lo que reduce el nivel de confianza requerido, e incluso puede rotarse entre los participantes.

7.2.3. Matización necesaria

Sería incorrecto presentar ambos enfoques como rivales excluyentes, y este trabajo no lo hace. Son primitivos distintos para problemas distintos, y de hecho convergen: los *clean rooms* incorporan cada vez más capacidades de cómputo, y las implantaciones federadas se apoyan en tecnologías —agregación segura, entornos de ejecución confiables— que también sustentan a los *clean rooms*.

La conclusión defendible es más acotada: para la tarea concreta de *entrenar un modelo de previsión de demanda entre operadores que no se ceden datos*, el aprendizaje federado es el primitivo adecuado, mientras que un *clean room* resolvería bien el análisis conjunto de datos que ya existen pero no evitaría la cesión que aquí se pretende eludir. Fuera de esa tarea, la comparación se decantaría con frecuencia del lado contrario, sobre todo si se pondera la madurez de las herramientas disponibles.

Por último, debe recordarse la advertencia regulatoria expuesta en el capítulo 2: el aprendizaje federado reduce la exposición pero no anonimiza por sí solo (Agencia Española de Protección de Datos & European Data Protection Supervisor, 2025). La

ventaja que aquí se defiende es la de no ceder datos crudos, no la de eliminar todo riesgo sobre la información.

Capítulo 8

Presupuesto

Este capítulo recoge el coste del proyecto. Se trata de una estimación: las horas se han asignado por fases a partir del registro de trabajo del proyecto, y las tarifas corresponden a valores de mercado para perfiles junior de ciencia de datos.

8.1. Coste de personal

El proyecto lo ha desarrollado una sola persona. La tabla 8.1 distribuye la dedicación por fases.

Tabla 8.1: Dedicación estimada por fases y coste de personal asociado.

Fase	Horas	Tarifa (€/h)	Coste (€)
Revisión bibliográfica y diseño experimental	45	30	1.350
Construcción del conjunto de datos	80	30	2.400
Métodos de referencia y condiciones A–C	70	30	2.100
Infraestructura federada y condiciones D–E	90	30	2.700
Ajuste de hiperparámetros y contraste estadístico	55	30	1.650
Despliegue en la nube (MLOps)	60	30	1.800
Análisis de negocio	30	30	900
Redacción de la memoria	70	30	2.100
Total	500		15.000

8.2. Coste de equipos

Se ha empleado un ordenador portátil personal. Se imputa la amortización correspondiente al periodo de uso del proyecto, seis meses, sobre una vida útil de cuatro años.

Tabla 8.2: Amortización de los equipos empleados.

Concepto	Precio (€)	Amortización	Coste imputado (€)
Ordenador portátil	1.400	6/48 meses	175

8.3. Coste de software y servicios en la nube

La totalidad de las herramientas empleadas son de código abierto y sin coste de licencia: Python, PyTorch, Flower, LightGBM, *scikit-learn*, pandas, DVC, Hydra, Streamlit y la distribución MiKTeX para la composición de esta memoria.

El único coste de servicios corresponde al despliegue distribuido en Microsoft Azure. El gasto real del ejercicio fue inferior a 5 €, gracias al uso de máquinas de la gama más económica y a la disciplina de detenerlas al terminar cada sesión. Se recoge en la tabla 8.3 el coste real y, a título orientativo, el que tendría una operación continuada del sistema durante un mes.

Tabla 8.3: Coste de software y de servicios en la nube.

Concepto	Coste (€)
Licencias de software (código abierto)	0
Microsoft Azure — experimentación realizada	5
Total imputado al proyecto	5
<i>(Referencia: operación continua de 3 máquinas, 1 mes)</i>	<i>≈ 75</i>

Merece la pena subrayar la asimetría entre este capítulo y el capítulo 7: el coste de cómputo del entrenamiento federado es marginal frente al beneficio estimado. El obstáculo para adoptar un esquema como el estudiado no es económico ni tecnológico, sino de gobierno del dato y de acuerdo entre las partes.

8.4. Resumen del presupuesto

Tabla 8.4: Resumen del presupuesto del proyecto.

Partida	Coste (€)
Personal	15.000
Equipos (amortización)	175
Software y servicios en la nube	5
Subtotal	15.180
Costes indirectos (10 %)	1.518
Total	16.698

Capítulo 9

Conclusiones y líneas futuras

9.1. Respuesta a las preguntas de investigación

RQ1 — ¿Mejora el modelo federado al local y se aproxima al centralizado?

La respuesta es doble y ninguna de sus dos mitades coincide con la hipótesis de partida.

El modelo federado *sin personalizar* **no** mejora al local: con un WMAPE de 0,1507 frente a 0,1476, es significativamente peor, y la diferencia es muy consistente entre series. Solo al añadir un ajuste fino por tienda el esquema federado se convierte en la mejor de las cinco condiciones, con 0,1379.

En cuanto a la aproximación al centralizado, la pregunta resulta estar mal planteada para este conjunto de datos: el modelo centralizado no es el techo de rendimiento que la formulación presupone, sino el peor de los cinco. La ordenación observada, $A < B < C$, indica que agregar datos de tiendas heterogéneas en un único modelo de capacidad limitada degrada el resultado en lugar de mejorarlo. En consecuencia, la métrica de «porcentaje de brecha recuperada» que se había previsto como indicador principal carece de sentido aquí, porque su premisa no se cumple. La afirmación correcta es más fuerte que la prevista: el esquema federado con personalización supera tanto al local como al centralizado.

RQ2 — ¿Supera el federado a los métodos convencionales?

Solo parcialmente. La condición E supera con claridad a la persistencia, al estacional y al suavizado exponencial. Frente a la media móvil de cuatro semanas la ventaja existe pero es mínima: sobre las series comunes es estadísticamente significativa, con un tamaño de efecto del 0,74 %. Y frente a un LightGBM global entrenado sobre datos agrupados, el esquema federado **pierde** por un 3,95 %, diferencia que el contraste confirma como real.

La conclusión honesta es que el aprendizaje federado no es superior a los mejores métodos no federados en este problema. Su interés no reside en la precisión absoluta sino en que alcanza un rendimiento comparable *sin necesidad de centralizar los datos*, que es justamente lo que los métodos que lo superan sí requieren.

RQ3 — ¿Qué valor económico genera?

Ponderando por volumen, la colaboración federada con personalización reduce el error de previsión un 16,50 % respecto a que cada tienda entrene en solitario, lo que supone evitar 807.857 unidades de error en ocho semanas. Traducido con parámetros de sector, el ahorro anual estimado para la red de 54 tiendas se sitúa entre 0,5 y 3,9 millones de euros, con un escenario central en torno a 1,8 millones, del orden de 35.000 € por tienda y año.

Ese beneficio, sin embargo, no es uniforme: se concentra en las series de mayor volumen —las 50 primeras explican el 84,6 % del total— y casi la mitad de las series empeoran. Una implantación real debería seleccionar por serie, sobre validación, entre el modelo personalizado y el local.

RQ4 — ¿Por qué federado y no un *data clean room*?

Porque resuelven tareas distintas. Un *clean room* está diseñado para consultar datos que ya existen dentro de un entorno operado por un tercero, lo que exige que los participantes depositen en él sus datos crudos. El problema aquí es entrenar un modelo predictivo, y el aprendizaje federado lo consigue haciendo circular parámetros en lugar de datos. La conclusión se limita deliberadamente a esta tarea: fuera de ella, y ponderando la madurez de las herramientas, la comparación se decantaría con frecuencia del lado contrario.

RQ5 — ¿Cuál es el coste en precisión de la privacidad diferencial?

Esta pregunta queda abierta. No se abordó experimentalmente, y es la línea de continuación más relevante del trabajo por la razón expuesta en el capítulo 6: los organismos reguladores advierten de que los parámetros intercambiados pueden seguir constituyendo datos personales, de modo que sin garantías formales el esquema reduce la exposición pero no anonimiza.

9.2. Conclusiones generales

Más allá de las respuestas concretas, el trabajo deja tres conclusiones de alcance más general.

La primera es que **la personalización no es un añadido opcional al aprendizaje federado sino la pieza que lo hace funcionar** en presencia de heterogeneidad. El modelo global federado, tomado aisladamente, no llegaba siquiera al modelo local.

La segunda es que **más datos no implican mejor modelo si la capacidad del modelo no acompaña**. La degradación monótona al centralizar es el resultado más contraintuitivo del estudio, y el hecho de que un LightGBM global sí saque partido de esos mismos datos agregados apunta a que el problema está en el reparto de capacidad y no en la agregación.

La tercera es metodológica: **optimizar los hiperparámetros de una etapa aislada puede perjudicar a la siguiente**. Un ajuste que mejoró el modelo federado en un 7 % empeoró la personalización posterior, con toda probabilidad por sobreajuste de una arquitectura mayor sobre los conjuntos pequeños del ajuste por tienda.

9.3. Líneas futuras

1. **Privacidad diferencial y agregación segura (RQ5)**, midiendo la curva de coste en precisión frente al presupuesto de privacidad. Es el paso necesario para poder sostener afirmaciones de anonimización.
2. **Selección por serie entre modelo personalizado y local**, decidida sobre validación. El análisis de robustez sugiere que capturaría el beneficio de las series que mejoran evitando el perjuicio de las que empeoran.

3. **Ajuste de hiperparámetros específico de la etapa de personalización**, con una arquitectura más contenida que la óptima para el entrenamiento federado.
4. **Validación con varios orígenes de previsión**, desplazando la ventana temporal, para obtener estimaciones más estables que las de un único corte de ocho semanas.
5. **Agrupación de participantes antes de federar**, en la línea de Long et al. (2025), como alternativa intermedia entre un modelo global y la personalización individual.
6. **Federación de modelos basados en árboles**, que en este problema son los más precisos y que no admiten el promediado de parámetros de FedAvg, lo que exigiría esquemas distintos.
7. **Evaluación sobre datos de operadores realmente distintos**, que es la limitación de fondo del estudio y la que más condicionaría sus conclusiones.

Bibliografía

- Agencia Española de Protección de Datos & European Data Protection Supervisor. (2025). *TechDispatch: Aprendizaje federado* (TechDispatch N.º 1). AEPD y EDPS. <https://www.aepd.es/guias/tech-dispatch-aprendizaje-federado.pdf>
- Arivazhagan, M. G., Aggarwal, V., Singh, A. K., & Choudhary, S. (2019). *Federated learning with personalization layers*. <https://arxiv.org/abs/1912.00818>
- Duan, N. (1983). Smearing estimate: A nonparametric retransformation method. *Journal of the American Statistical Association*, 78(383), 605-610. <https://doi.org/10.1080/01621459.1983.10478017>
- IAB Tech Lab. (2024, julio). *Data Clean Rooms: Guidance and Recommended Practices* (Guidance). IAB Technology Laboratory. <https://iabtechlab.com/datacleanrooms/>
- Kaggle. (2023). *Store Sales — Time Series Forecasting* [Conjunto de datos]. Consultado el 9 de julio de 2026, desde <https://www.kaggle.com/competitions/store-sales-time-series-forecasting>
- Li, T., Sahu, A. K., Zaheer, M., Sanjabi, M., Talwalkar, A., & Smith, V. (2020). Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems*, 2, 429-450. <https://arxiv.org/abs/1812.06127>
- Long, Y., Xu, L., Zheng, G., & Brintrup, A. (2025). *PA-CFL: Privacy-adaptive clustered federated learning for transformer-based sales forecasting on heterogeneous retail data*. <https://arxiv.org/abs/2503.12220>
- McMahan, B., Moore, E., Ramage, D., Hampson, S., & Agüera y Arcas, B. (2017). Communication-efficient learning of deep networks from decentralized data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 1273-1282. <https://proceedings.mlr.press/v54/mcmahan17a.html>
- Petropoulos, F., Grushka-Cockayne, Y., Siemsen, E., & Spiliotis, E. (2024). Wielding Occam’s razor: Fast and frugal retail forecasting. *Journal of the Operational Research Society*. <https://doi.org/10.1080/01605682.2024.2421339>
- Snowflake Inc. (2026). *Data clean rooms*. Consultado el 14 de julio de 2026, desde <https://www.snowflake.com/en/product/features/data-clean-rooms/>

Apéndice A

Anexos

A.1. Repositorio y reproducibilidad

Todo el código, la documentación y los resultados intermedios del proyecto están versionados en un repositorio Git. La organización es la siguiente:

- **src/** — los guiones numerados que componen el flujo de trabajo, desde la descarga de los datos hasta el análisis económico, más los módulos compartidos de modelo, métricas e infraestructura federada.
- **flower_app/** — la aplicación de Flower para el despliegue distribuido.
- **infra/** — los guiones de aprovisionamiento y operación de la infraestructura en la nube.
- **conf/** y **configs/** — configuración de los experimentos y parámetros seleccionados en las búsquedas.
- **reports/** — resultados en formato tabular; todas las cifras de esta memoria proceden de estos ficheros.
- **tests/** — pruebas automatizadas.
- **docs/** — cuaderno de laboratorio, diccionario de datos, plan y bibliografía.
- **memoria/** — fuentes de este documento.

La reproducibilidad se apoya en varios mecanismos. El flujo de preparación de datos está declarado como un grafo de dependencias con DVC, de modo que un único comando

regenera el conjunto desde los datos crudos; se comprobó que la ejecución reproduce exactamente las cifras documentadas. La configuración de los experimentos se gestiona con Hydra, lo que permite variar hiperparámetros desde la línea de comandos sin editar código. Las semillas aleatorias están fijadas, y como comprobación independiente, el recálculo de las siete condiciones y métodos realizado meses después para el contraste estadístico reprodujo las siete medianas publicadas con exactitud.

El repositorio incorpora además integración continua que ejecuta el análisis estático de código y la batería de pruebas en cada envío de cambios. Las pruebas que dependen de los datos procesados —que no se versionan por su tamaño— se omiten automáticamente cuando no están disponibles.

A.2. Cuaderno de laboratorio

Cada paso del proyecto con resultados asociados se registró en un cuaderno de laboratorio con estructura de sección de métodos y resultados: objetivo, procedimiento exacto, comandos reproducibles, cifras obtenidas, interpretación y justificación de las decisiones. El historial es inmutable: las entradas cerradas no se editan y las correcciones se añaden como entradas nuevas que referencian a las anteriores. Ese cuaderno es la fuente de la que procede el contenido de los capítulos 4 and 5, y en él quedan documentados también los errores cometidos y corregidos durante el desarrollo, como el desalineamiento de los retardos descrito en el capítulo 4.

A.3. Dificultades del despliegue en la nube

El despliegue distribuido descrito en el capítulo 5 exigió resolver una sucesión de obstáculos que no aparecen en la literatura pero que condicionan cualquier implantación real. Se recogen aquí porque forman parte del resultado de ingeniería del trabajo.

- **Restricciones de la suscripción.** La región inicialmente prevista estaba vetada por política para la suscripción disponible, y hubo que sondear regiones alternativas hasta encontrar una admitida.
- **Cuota y disponibilidad de máquinas.** La cuota de la suscripción limitaba el número de núcleos, y las máquinas más pequeñas no tenían capacidad disponible en la región elegida. Ello obligó a rediseñar la arquitectura de cuatro nodos a tres, alojando el agregador en uno de los silos. Es un patrón legítimo en federaciones

entre organizaciones, en las que con frecuencia uno de los participantes hospeda la coordinación, y no altera el aislamiento de los datos: el agregador solo maneja parámetros y un conjunto de validación de referencia.

- **Consistencia eventual de la nube.** Varios recursos recién creados no eran consultables de inmediato, lo que obligó a introducir reintentos selectivos en el aprovisionamiento.
- **Versiones del entorno.** La imagen del sistema operativo incorporaba una versión de Python anterior a la exigida por el marco federado, lo que requirió instalarla explícitamente; y fue necesario fijar la versión exacta del marco en todos los nodos, ya que el protocolo de comunicación no tolera discrepancias.
- **Propagación del entorno de ejecución.** El proceso que ejecuta la aplicación del servidor no hereda las variables de entorno del proceso que lo lanza, de modo que la configuración del registro de métricas hubo de pasarse por el mecanismo de configuración del propio marco.

Todas estas soluciones quedaron incorporadas a los guiones de aprovisionamiento, de manera que el despliegue completo es reproducible mediante una secuencia documentada de comandos.

A.4. Cuadro de mando de resultados

Como complemento a esta memoria se desarrolló un cuadro de mando interactivo que permite explorar la comparación entre métodos, la convergencia del entrenamiento federado y el detalle por serie de la condición personalizada. Lee los mismos ficheros de resultados que sustentan las tablas y figuras de este documento, sin recalcular nada.