
Tecnun — Escuela de Ingeniería, Universidad de Navarra
Máster Universitario en Análisis de Datos en Ingeniería (MADI)

Aprendizaje federado para la previsión de demanda en *retail*

Evaluación frente a modelos locales, centralizados y convencionales

Alessandro Flammia

Tutora: Idoia Ochoa

Resumen de la memoria del Trabajo Fin de Máster
Septiembre de 2026

Qué contiene esta presentación

1. El problema

Por qué los datos que mejorarían la previsión están en manos de quien no puede compartirlos.

2. El enfoque y las preguntas

Qué es el aprendizaje federado y qué se pregunta exactamente este trabajo.

3. Datos y método

Un histórico real de 54 tiendas, cinco condiciones experimentales y un único protocolo de evaluación.

4. Resultados

Qué funcionó, qué no, y qué dice el contraste estadístico sobre cada diferencia.

5. Del simulador a la nube

Verificación del esquema sobre tres máquinas independientes con aislamiento real de datos.

6. Valor de negocio

Cuánto vale colaborar, para quién, y dónde la cifra agregada esconde matices.

7. Conclusiones

Respuesta a las cinco preguntas de investigación y líneas abiertas.

Todas las cifras de esta presentación proceden de los resultados documentados en la memoria y son trazables a los ficheros de resultados del repositorio.

Los datos que harían falta no se pueden compartir

La previsión mejora con más datos

Un operador con más tiendas y más historial dispone de más señal para estimar la demanda: más patrones estacionales, más respuestas a promoción, más casos de cada familia de producto.


Pero los datos están repartidos entre competidores

Los operadores que más se beneficiarían de un modelo conjunto compiten entre sí. Ceder el histórico de ventas no es viable ni comercial ni legalmente.

Resultado: cada uno entrena en solitario

Con una fracción de los datos que realmente existen sobre el mismo problema.

¿Se puede entrenar un modelo conjunto sin que nadie ceda sus datos?



Aprendizaje federado: circulan los parámetros, no los datos

En lugar de reunir los datos en un sitio, cada participante entrena **con los suyos** y envía únicamente los **pesos** del modelo. Un coordinador los promedia y devuelve el modelo global. Se repite por rondas.


Los datos no salen nunca del silo

El coordinador no custodia datos: solo maneja parámetros y un conjunto de validación de referencia.

Participan los silos, no las tiendas

Escenario *cross-silo*: tres participantes, cada uno con sus propias tiendas centralizadas internamente, que es legítimo porque son del mismo operador.

Advertencia recogida en la memoria: los parámetros intercambiados pueden seguir constituyendo datos personales (AEPD y EDPS, 2025). El esquema reduce la exposición, pero por sí solo no anonimiza.



Las cinco preguntas de investigación

RQ1 — técnica

¿Predice el federado mejor que el modelo local de cada tienda y se aproxima al centralizado, sin compartir datos crudos? Incluye la personalización posterior como variante.

RQ2 — técnica

¿Supera a los métodos convencionales: baselines ingenuos, suavizado exponencial y árboles potenciados por gradiente?

RQ3 — negocio

¿Qué valor económico genera la mejora de precisión atribuible a la colaboración?

RQ4 — negocio

¿Por qué un esquema federado y no un *data clean room*?

RQ5 — ampliación

¿Qué coste en precisión tendría añadir privacidad diferencial? *No se aborda; queda como línea futura.*

Una formulación neutra

El trabajo no parte de la hipótesis de que el aprendizaje federado sea superior, sino de la pregunta de si lo es.

Admite como resultado válido que **no** lo sea — y, como se verá, esa es en parte la respuesta.

Un histórico real, dividido en silos heterogéneos

Corporación Favorita (Ecuador), datos abiertos

Ventas de **54 tiendas** y **33 familias** entre 2013 y 2017, con festivos, precio del petróleo y promociones.

Granularidad: tienda × familia × semana

1.782 series y 322.245 filas. Es la granularidad de la reposición agregada y evita la intermitencia del nivel diario por referencia.


Silos por formato de tienda

Grande (9), Mediano (26) y Pequeño (19). La heterogeneidad está sobre todo en la *escala* de venta — factores de 2 a 3 veces — y en la intensidad promocional.

Partición temporal estricta

220 semanas de entrenamiento, 8 de validación y 8 de prueba, en orden cronológico.

Composición de los 3 silos (Propuesta 2)



Limitación declarada: los silos son formatos de tienda de una misma cadena, no operadores competidores reales. Es la metodología estándar del campo ante la ausencia de datos públicos entre cadenas, y se declara explícitamente como limitación del estudio.

Nota metodológica: se detectó y corrigió un desalineamiento silencioso de los retardos causado por el hueco del 25 de diciembre, que afectaba a 1.749 de las 1.782 series.

Cinco condiciones, un mismo modelo, un mismo protocolo

- A** — Local un modelo por tienda, sin colaboración
- B** — Centralizado por silo un modelo por formato de tienda
- C** — Centralizado global un modelo con los tres silos juntos
- D** — Federado FedAvg entre los silos (y FedProx)
- E** — Federado + person. ajuste fino por tienda sobre D


Referencias externas

Persistencia, estacional de 52 semanas, media móvil de 4 semanas, ETS/Holt-Winters y un **LightGBM global**, como exigencia máxima no federada.

Métrica y contraste

WMAPE por serie, agregado por la mediana. Test de **Wilcoxon** **pareado** con corrección de **Holm-Bonferroni**.

El modelo, común a las cinco condiciones



Perceptrón multicapa con *embeddings* de entidad: **4.985 parámetros**.

El tamaño reducido es deliberado — en federado el coste de comunicación es proporcional a los parámetros que se intercambian en cada ronda.

Dos resultados que contradicen la hipótesis de partida

WMAPE en prueba (mediana de las series)

C — Centralizado global 0,1736

B — Centralizado por silo 0,1676

A — Local 0,1476

D — Federado 0,1507


E — Federado + person. 0,1379

Centralizar empeora, de forma monótona

El modelo global (C) dispone de unas 54 veces más datos que un modelo local y es **el peor de los cinco**. No es falta de entrenamiento: más paciencia solo produce sobreajuste.


Federar sin personalizar no compensa

D (0,1507) **no alcanza** al modelo local A (0,1476). Es el ajuste fino por tienda el que convierte al federado en la mejor de las cinco condiciones.



La diferencia entre condiciones es pequeña frente a la variabilidad entre series: las medianas ordenan bien los métodos, pero conviven con una dispersión considerable. De ahí la necesidad del contraste pareado.

Frente a los métodos convencionales: el federado no gana



El mejor método del estudio no es federado

Un **LightGBM global** sobre los datos agrupados obtiene 0,1320 frente a los 0,1379 de la mejor condición federada.


La media móvil de 4 semanas iguala en mediana

El más simple de los métodos alcanza también 0,1379. El contraste pareado matiza este aparente empate.

¿Y si el federado solo estaba mal ajustado? Se hizo búsqueda de hiperparámetros: mejoró D un 7 % (0,1507 → 0,1402), pero **no se trasladó** a E. La conclusión no cambia.

El valor del federado no está en la precisión absoluta, sino en alcanzar un rendimiento comparable *sin centralizar los datos* — que es justo lo que los métodos que lo superan sí exigen.

Ninguna de estas diferencias es ruido



Wilcoxon pareado por serie sobre las ocho comparaciones, con corrección de Holm-Bonferroni. **Todos** resultan significativos al 5 %.

La escalera de centralización es real

Que B y C sean peores que A son los dos contrastes con los p-valores más pequeños del estudio.

La personalización es la pieza que funciona

D vs E combina un efecto apreciable (−8,31 %) con significación muy alta.

El valor de colaborar es real, pero es el efecto más débil

El contraste A vs E — el que sostiene el análisis económico — mejora un 6,57 % con $p = 0,035$: el menos robusto de los ocho.

Sobre el aparente empate con la media móvil: las medianas globales se calculan sobre conjuntos de series distintos. En las 1.655 series comunes, E gana de forma significativa, pero solo por un 0,74 %.

El esquema se comporta igual fuera de la simulación

Los resultados anteriores se obtuvieron con el motor de simulación de Flower, que representa los silos como procesos de una misma máquina. Eso no verifica que el esquema funcione sobre infraestructura realmente distribuida.


Tres máquinas virtuales independientes

Cada una contiene **únicamente** el conjunto de datos de su silo. El aislamiento es efectivo, no simulado.

El agregador se aloja en un silo

Impuesto por la cuota de la suscripción, es un patrón legítimo en federaciones entre organizaciones y no altera el aislamiento: solo maneja parámetros.

El despliegue exigió resolver restricciones de región, cuota de núcleos, consistencia eventual de los recursos y discrepancias de versión entre nodos. Todo quedó incorporado a los guiones de aprovisionamiento, de modo que el despliegue es reproducible.



Cuánto vale colaborar en vez de entrenar en solitario

16,50 %

menos error de previsión al pasar de A (local) a E (federado + personalización), **ponderando por volumen**

807.857

unidades de error evitadas en las ocho semanas de prueba

0,5 – 3,9 M€

ahorro anual estimado para la red de 54 tiendas; escenario central 1,84 M€ (≈ 34.700 €/tienda)

Parte física y parte monetaria, separadas

La reducción de error sale *íntegramente* de los resultados del trabajo. La traducción a euros usa parámetros de sector y se presenta siempre como **rango con análisis de sensibilidad**, nunca como cifra única.

El beneficio no es uniforme

Se concentra en las series de mayor volumen — las 50 primeras explican el **84,6 %** del ahorro — y **764 de 1.655 series (46,2 %) empeoran**.

Recomendación

Seleccionar serie a serie, sobre validación, entre el modelo personalizado y el local.



La mediana de mejora es del 6,57 % y la ponderada por volumen del 16,50 %: la personalización acierta justo donde hay volumen. Es la cifra económicamente relevante, pero también la que esconde a las series que empeoran.

Por qué federado y no un *data clean room*

Dimensión	<i>Data clean room</i>	Aprendizaje federado
Tarea que resuelve	Consultas sobre datos que ya existen	Entrenamiento de un modelo predictivo nuevo
Movimiento de datos	Se copian a un entorno común	No salen de cada participante
Tercero de confianza	Necesario: alguien opera el entorno	No custodia datos; solo parámetros
Madurez	Alta, oferta comercial consolidada	Menor, marcos abiertos en evolución

La diferencia es de tarea, no de nivel de protección

Un *clean room* responde preguntas sobre datos que ya existen. Aquí hay que **construir** un modelo, lo que exigiría que todos depositaran sus datos crudos en el entorno de un tercero — exactamente la cesión que se quería evitar.

Y una consideración práctica

Entre competidores, acordar *quién* opera el entorno suele ser el verdadero obstáculo. El coordinador federado no custodia datos e incluso puede rotarse.

Matización necesaria: no son alternativas excluyentes, sino primitivos distintos para problemas distintos. De hecho convergen. La conclusión se limita deliberadamente a esta tarea.

Respuesta a las preguntas de investigación

RQ1 — Ninguna mitad coincide con la hipótesis

El federado *sin* personalizar no mejora al local. Y el centralizado no es el techo de rendimiento, sino el peor de los cinco. La afirmación correcta es más fuerte que la prevista: **E supera tanto al local como al centralizado.**

RQ2 — Solo parcialmente

Bate a persistencia, estacional y ETS; gana por poco a la media móvil; y **pierde** frente a LightGBM por un 3,95 % real.

RQ3 — Valor real, con matices

16,50 % menos error ponderado por volumen y del orden de 1,8 M€ anuales, pero concentrado y con casi la mitad de las series empeorando.

RQ4 — Resuelven tareas distintas

Para *entrenar* un modelo entre partes que no ceden datos, el federado es el primitivo adecuado.

Tres conclusiones de alcance general

1. La personalización no es un añadido opcional al aprendizaje federado, sino **la pieza que lo hace funcionar** en presencia de heterogeneidad.
2. Más datos no implican mejor modelo **si la capacidad no acompaña**. Que un LightGBM sí saque partido de esos mismos datos agregados apunta al reparto de capacidad, no a la agregación.
3. Optimizar los hiperparámetros de una etapa aislada **puede perjudicar a la siguiente**: el ajuste que mejoró D un 7 % empeoró la personalización posterior.

RQ5 queda abierta y es la continuación más relevante: sin garantías formales, el esquema reduce la exposición pero no anonimiza.

Líneas futuras

- **Privacidad diferencial y agregación segura** (RQ5), midiendo la curva de coste en precisión frente al presupuesto de privacidad. Es el paso necesario para poder sostener afirmaciones de anonimización.
- **Selección por serie** entre modelo personalizado y local, decidida sobre validación: capturaría el beneficio de las series que mejoran evitando el perjuicio de las que empeoran.
- **Ajuste de hiperparámetros específico** de la etapa de personalización, con una arquitectura más contenida.
- **Validación con varios orígenes de previsión**, desplazando la ventana temporal, para estimaciones más estables que las de un único corte de ocho semanas.
- **Federación de modelos basados en árboles**, que en este problema son los más precisos y que no admiten el promediado de parámetros de FedAvg.
- **Evaluación sobre operadores realmente distintos**, que es la limitación de fondo del estudio.

El detalle completo está en la memoria

59 páginas, 8 capítulos y anexos, con la metodología, los resultados intermedios, la discusión y las limitaciones desarrolladas.

Todo el código, los resultados y el cuaderno de laboratorio del proyecto están versionados en el repositorio.

Alessandro Flammia

Máster en Análisis de Datos en Ingeniería — Tecnun